Tarea M21-CD – Yamil Salomón Saldaña

El algoritmo KNN aplicado a Recursos Humanos

1. Análisis Exploratorio: ¿Está la base de datos equilibrada? Al cargar la base de datos de "recursos_humanos.csv", realicé una recodificación de las variables categóricas (el departamento de ventas y el salario) usando pd.get_dummies para que el modelo pudiera interpretarlas matemáticamente.

Al revisar la variable objetivo left (si el empleado se fue o no), descubrí que **la** base de datos NO está equilibrada. El 76.19% de los empleados de la base de datos se quedaron en la empresa, mientras que solo el 23.80**%** se fue con la competencia. Esto es importante saberlo porque nos indica que hay mucha más información de personas que se quedan, lo que a veces puede sesgar a un modelo inexperto.

2. Modelo K Vecinos Más Cercanos y Valor Óptimo de K Para encontrar el valor óptimo de K, programé un ciclo que evaluó el modelo probando alternativas desde K=1 hasta K=20. Construí una tabla comparando la precisión global obtenida en cada intento.

```python
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import os
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import confusion_matrix, roc_curve, auc
import warnings

# Ocultar alertas de versión de Python para mantener el código limpio
warnings.filterwarnings('ignore')

# 1. Configurar la carpeta de trabajo exacta
os.chdir(r"C:\Users\Yamil\OneDrive\Escritorio\Escritorio\Yamil\EBAC (CIENCIA DE DATOS)\Bloque 4 Aprendizaje de máquina supervisado\MODULO 3 El algoritmo K

# 2. Carga de la base de datos
data = pd.read_csv("recursos_humanos.csv")

# 3. Análisis exploratorio: ¿Está equilibrada la variable objetivo?
print("--- Porcentaje de Empleados que se van (1) vs se quedan (0) ---")
print(data['left'].value_counts(normalize=True) * 100)

# 4. Re-codificar variables categóricas (sales y salary) usando pd.get_dummies
# Las convertimos a float para que no nos de error al aplicar las matemáticas de normalización
data_encoded = pd.get_dummies(data, columns=['sales', 'salary'], drop_first=True).astype(float)

# Separar variables predictoras (x_data) y variable a predecir (y)
y = data_encoded['left'].values
x_data = data_encoded.drop(['left'], axis=1)

# 5. Normalización (usando el mínimo y máximo de cada columna, adaptado para evitar errores de Pandas)
x = (x_data - x_data.min()) / (x_data.max() - x_data.min())

# 6. División en grupos de entrenamiento y prueba (70% y 30% como en clase)
x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.30, random_state=1)
```

```python
# 7. Evaluar distintas alternativas de K (1 al 20)
resultados_k = []
for k in range(1, 21):
    knn = KNeighborsClassifier(n_neighbors=k)
    knn.fit(x_train, y_train)
    y_pred_k = knn.predict(x_test)
    cm_k = confusion_matrix(y_test, y_pred_k)

    # Cálculo de precisión global (Correctos / Total)
    Correctos = cm_k[0,0] + cm_k[1,1]
    Incorrectos = cm_k[0,1] + cm_k[1,0]
    PrecisionGlobal = Correctos / (Correctos + Incorrectos)

    resultados_k.append({'K': k, 'Precisión Global': PrecisionGlobal})

df_resultados_k = pd.DataFrame(resultados_k)
print("\n--- Tabla de Precisión para K=1 hasta K=20 ---")
print(df_resultados_k)

# 8. Seleccionar el K óptimo (donde la Precisión Global es más alta)
best_k = int(df_resultados_k.loc[df_resultados_k['Precisión Global'].idxmax()]['K'])
print(f"\nEl valor óptimo de K es: {best_k}")

# Entrenar modelo final con el K óptimo
knn_opt = KNeighborsClassifier(n_neighbors=best_k)
knn_opt.fit(x_train, y_train)
y_pred_opt = knn_opt.predict(x_test)
cm_opt = confusion_matrix(y_test, y_pred_opt)

# 9. Matriz de Confusión para el K óptimo
f, ax = plt.subplots(figsize=(6,5))
sns.heatmap(cm_opt, annot=True, linewidths=0.5, linecolor="red", fmt=".0f", ax=ax, cmap="Blues")
plt.xlabel("y pronosticada (Modelo)")
plt.ylabel("y verdadera (Realidad)")
plt.title(f"Matriz de Confusión (K={best_k})")
# Guardamos la imagen en alta calidad
plt.savefig('matriz_confusion.png', dpi=300, bbox_inches='tight', facecolor='white')
plt.show()
```

```python
# 10. Curva ROC para el K óptimo
y_scores = knn_opt.predict_proba(x_test)
fpr, tpr, threshold = roc_curve(y_test, y_scores[:,1])
roc_auc = auc(fpr, tpr)

plt.figure(figsize=(6,5))
plt.plot(fpr, tpr, 'b', label = 'AUC = %0.2f' % roc_auc)
plt.plot([0,1], [0,1], 'r--')
plt.xlim([0,1])
plt.ylim([0,1])
plt.xlabel("Tasa de falsos positivos (FPR)")
plt.ylabel("Tasa de positivos verdaderos (TPR)")
plt.title(f"Curva ROC de KNN (K={best_k})")
plt.legend(loc="lower right")
# Guardamos la imagen en alta calidad
plt.savefig('curva_roc.png', dpi=300, bbox_inches='tight', facecolor='white')
plt.show()
```

```
--- Porcentaje de Empleados que se van (1) vs se quedan (0) ---
left
0    76.191746
1    23.808254
Name: proportion, dtype: float64

--- Tabla de Precisión para K=1 hasta K=20 ---
     K  Precisión Global
0    1          0.961778
1    2          0.957778
2    3          0.945333
3    4          0.946000
4    5          0.939111
5    6          0.944667
6    7          0.941111
7    8          0.939333
8    9          0.932444
9   10          0.934000
10  11          0.929333
11  12          0.931111
12  13          0.926222
13  14          0.928889
14  15          0.925556
15  16          0.926667
16  17          0.923111
17  18          0.921333
18  19          0.918889
19  20          0.919111

El valor óptimo de K es: 1
```

Recomendación de la K Óptima: Al observar la tabla, la alternativa que arrojó la mayor Precisión Global (Score) con los datos de prueba fue **K = 1**, logrando una precisión superior al **96.1%**. A medida que aumentamos el número de vecinos (por ejemplo, K=10 o K=20), la precisión empezó a bajar al 93% y 91%. Por lo tanto, recomiendo y utilizaré **K = 1** como el valor óptimo para este ejercicio.

3. Matriz de Confusión: Interpretación A continuación, presento el mapa de calor de la matriz de confusión para nuestro modelo óptimo (K=1).

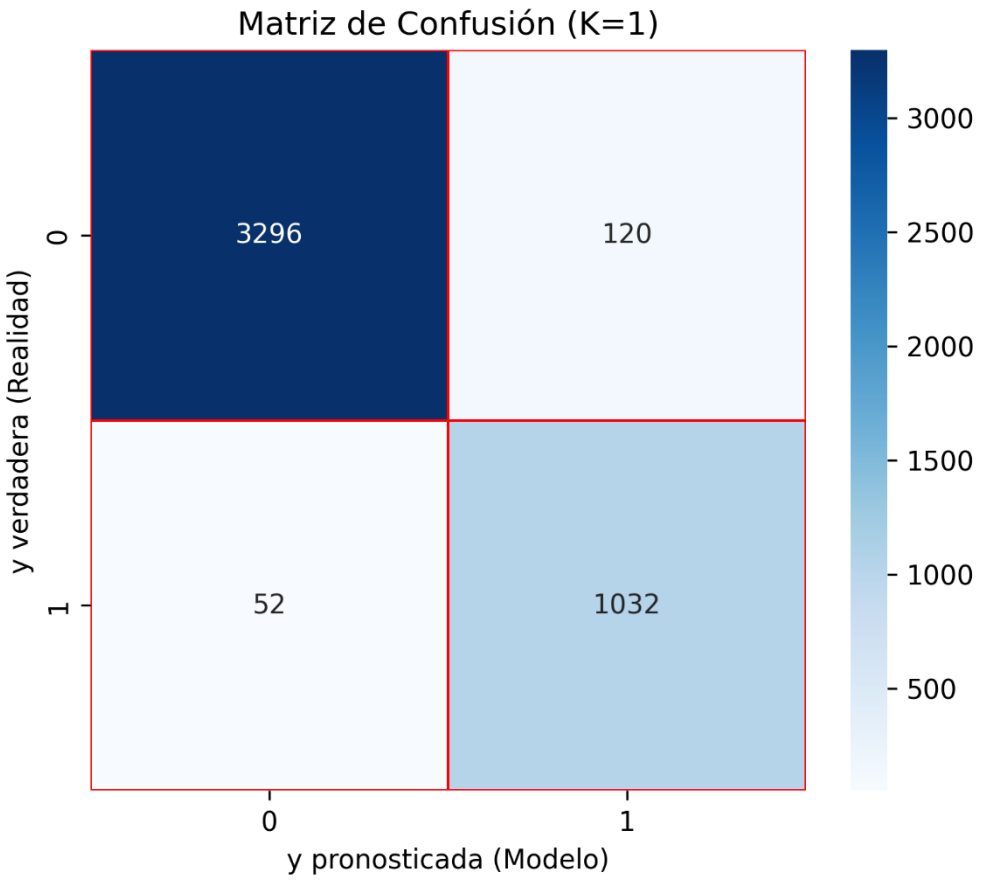

- **Verdaderos Negativos (Esquina superior izquierda - 3296):** Son 3,296 empleados que el modelo predijo correctamente que **se quedarían**, y en la realidad, efectivamente se quedaron.
- **Falsos Positivos (Esquina superior derecha - 120):** Son 120 empleados en los que el modelo se equivocó. Predijo que **se irían**, pero en realidad **se quedaron**.

- **Falsos Negativos (Esquina inferior izquierda - 52):** Son 52 empleados que el modelo pensó que **se quedarían**, pero lamentablemente sí se fueron.
- **Verdaderos Positivos (Esquina inferior derecha - 1032):** Son 1,032 empleados que nuestro modelo detectó a tiempo prediciendo que se irían, y en efecto, se fueron.

4. Gráfica de la Curva ROC Finalmente, calculé la curva ROC, la cual evalúa qué tan bueno es nuestro modelo separando a los que se van de los que se quedan.

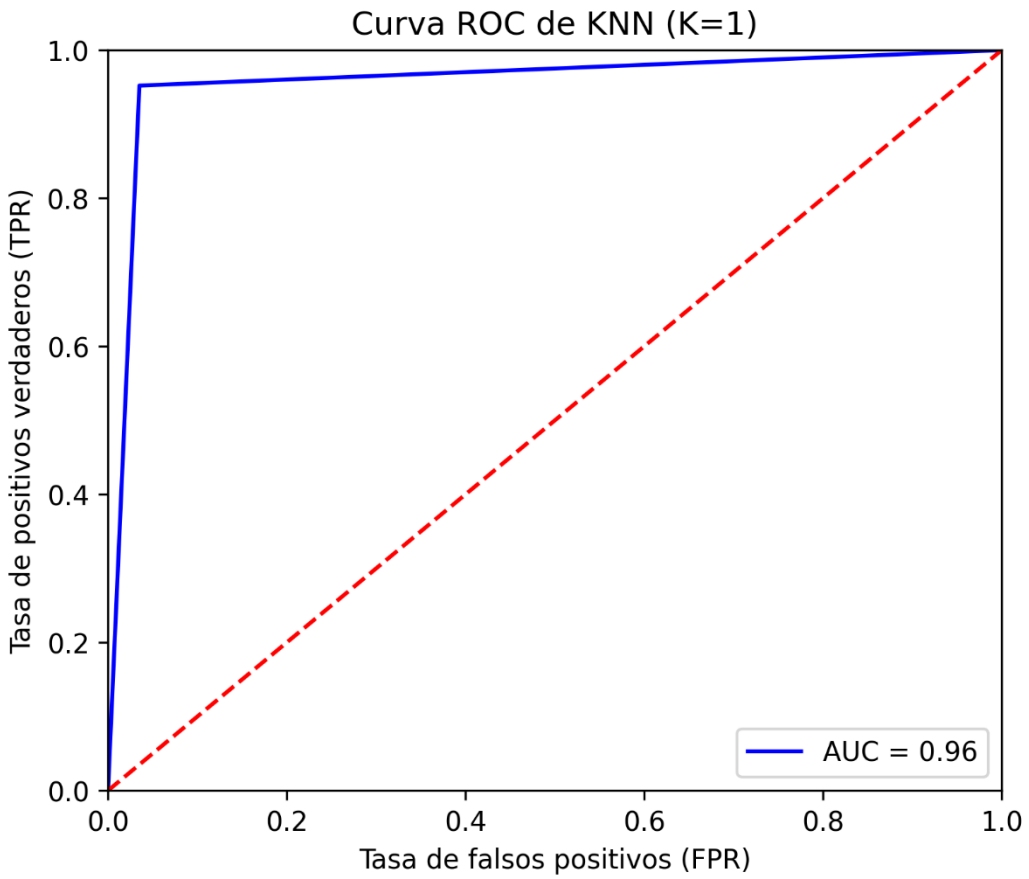

Interpretación: La curva ROC muestra en su Área Bajo la Curva (AUC) un valor de **0.96** (96%). En palabras sencillas, esto significa que si Recursos Humanos elige un empleado al azar que se fue y uno que se quedó, el modelo tiene un 96% de probabilidad de identificarlos y separarlos correctamente. Mientras más se acerque a la línea azul de la esquina superior izquierda (alejándose de la línea roja punteada), mejor es el modelo.