Análisis de Clasificación Clínica mediante Árboles de Decisión

Alumno: Yamil Salomon

1. Conversión de variables predictoras cualitativas a escala numérica:

Para poder entrenar el árbol de decisión con la base de datos drugs.csv, fue indispensable realizar un preprocesamiento de los datos. Dado que los algoritmos matemáticos requieren datos numéricos para calcular las divisiones en los nodos, utilicé la función preprocessing.LabelEncoder() de la librería Scikit-Learn. Con esto, logré transformar las variables cualitativas de "Sexo" (F, M), "Presión Arterial" (LOW, NORMAL, HIGH) y "Colesterol" (NORMAL, HIGH) en una escala numérica estructurada (0, 1 y 2).

2. Evaluación de Modelos (Gini vs Entropía) y Selección de la mejor opción:

Para encontrar el modelo predictivo más robusto, generé múltiples árboles de decisión iterando entre dos criterios de clasificación: Gini (que mide la impureza de los datos) y Entropía (que evalúa la ganancia de información). Además, para evitar que el modelo se memorizara los datos (sobreajuste), probé limitando el crecimiento del árbol a diferentes niveles de profundidad (3, 4 y 5).

```
import os
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.model_selection import train_test_split
from sklearn import metrics, preprocessing
import warnings
warnings.filterwarnings('ignore')

# 1. Configurar la ruta exacta
os.chdir(r"C:\Users\Yamil\OneDrive\Escritorio\Escritorio\Yamil\EBAC (CIENCIA DE DATOS)\Bloque 4 Aprendizaje de máquina supervisado\MOD

# 2. Cargar la base de datos
df = pd.read_csv("drugs.csv")

# 3. CONVERSIÓN DE VARIABLES CUALITATIVAS (LabelEncoder)
feature_cols = ['Age', 'Sex', 'BP', 'Cholesterol', 'Na_to_K']
X = df[feature_cols].values
y = df['Drug'].values

# Sexo (F/M) -> (0/1)
Cod_Sex = preprocessing.LabelEncoder()
Cod_Sex.fit(['F', 'M'])
X[:, 1] = Cod_Sex.transform(X[:, 1])
```

```python
# Presión (LOW, NORMAL, HIGH) -> (0, 1, 2)
Cod_BP = preprocessing.LabelEncoder()
Cod_BP.fit(['LOW', 'NORMAL', 'HIGH'])
X[:, 2] = Cod_BP.transform(X[:, 2])

# Colesterol (NORMAL, HIGH) -> (0, 1)
Cod_Chol = preprocessing.LabelEncoder()
Cod_Chol.fit(['NORMAL', 'HIGH'])
X[:, 3] = Cod_Chol.transform(X[:, 3])

# 4. Creación de grupos de entrenamiento y prueba (70/30)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=3)

# 5. EVALUACIÓN DE MODELOS: GINI VS ENTROPÍA (Distintas profundidades)
criterios = ['gini', 'entropy']
profundidades = [3, 4, 5]

best_acc = 0
best_model = None
best_name = ""

print("--- REPORTES DE CLASIFICACIÓN DETALLADOS ---\n")
for crit in criterios:
    for prof in profundidades:
        clf = DecisionTreeClassifier(criterion=crit, max_depth=prof, random_state=3)
        clf.fit(X_train, y_train)
        y_pred = clf.predict(X_test)

        acc = metrics.accuracy_score(y_test, y_pred)
        print(f"=== Modelo: Criterio {crit.upper()} | Profundidad: {prof} ===")
        print(metrics.classification_report(y_test, y_pred))
        print("-" * 50)

        if acc > best_acc:
            best_acc = acc
            best_model = clf
            best_name = f"{crit.upper()} con Profundidad {prof}"

print(f"\nMEJOR MODELO SELECCIONADO: {best_name} (Exactitud: {best_acc:.4f})")

# 6. VISUALIZACIÓN DEL ÁRBOL
plt.figure(figsize=(15, 10))
plot_tree(best_model, feature_names=feature_cols, class_names=np.unique(y), filled=True, rounded=True)
plt.title(f"Reglas del Árbol de Decisión - {best_name}")
plt.savefig("arbol_drogas.png", facecolor='white', dpi=300, bbox_inches='tight')
plt.show()

# 7. PRONÓSTICO PARA EL PACIENTE NUEVO
# ---> YAMIL: INGRESA LOS VALORES DE LA IMAGEN 2 AQUÍ EN ESTE ORDEN <---
# Orden: [Edad, 'F' o 'M', 'LOW', 'NORMAL' o 'HIGH', 'NORMAL' o 'HIGH', Na_to_K]
nuevo_paciente = [[47, 'M', 'LOW', 'HIGH', 13.093]] # <--- REEMPLAZA ESTOS DATOS POR LOS DE TU IMAGEN

# Transformamos los datos del paciente nuevo para que el modelo los entienda
nuevo_paciente[0][1] = Cod_Sex.transform([nuevo_paciente[0][1]])[0]
nuevo_paciente[0][2] = Cod_BP.transform([nuevo_paciente[0][2]])[0]
nuevo_paciente[0][3] = Cod_Chol.transform([nuevo_paciente[0][3]])[0]

prediccion = best_model.predict(nuevo_paciente)
print(f"\n--- RECOMENDACIÓN MÉDICA PARA EL NUEVO PACIENTE ---")
print(f"Medicamento a prescribir: {prediccion[0]}")
```

-- REPORTES DE CLASIFICACIÓN DETALLADOS ---

=== Modelo: Criterio GINI | Profundidad: 3 ===

	precision	recall	f1-score	support
drugA	1.00	1.00	1.00	7
drugB	1.00	1.00	1.00	5
drugC	0.33	1.00	0.50	5
drugX	1.00	0.48	0.65	21
drugY	0.96	1.00	0.98	22
accuracy			0.82	60
macro avg	0.86	0.90	0.82	60
weighted avg	0.93	0.82	0.83	60

=== Modelo: Criterio GINI | Profundidad: 4 ===

	precision	recall	f1-score	support
drugA	1.00	1.00	1.00	7
drugB	1.00	1.00	1.00	5
drugC	1.00	1.00	1.00	5
drugX	1.00	0.95	0.98	21
drugY	0.96	1.00	0.98	22
accuracy			0.98	60
macro avg	0.99	0.99	0.99	60
weighted avg	0.98	0.98	0.98	60

=== Modelo: Criterio GINI | Profundidad: 5 ===

	precision	recall	f1-score	support
drugA	1.00	1.00	1.00	7
drugB	1.00	1.00	1.00	5

```
       drugC      1.00      1.00      1.00         5
       drugX      1.00      0.95      0.98        21
       drugY      0.96      1.00      0.98        22

    accuracy                           0.98        60
   macro avg       0.99      0.99      0.99        60
weighted avg       0.98      0.98      0.98        60

--------------------------------------------------
=== Modelo: Criterio ENTROPY | Profundidad: 3 ===
              precision    recall  f1-score   support

       drugA      1.00      1.00      1.00         7
       drugB      1.00      1.00      1.00         5
       drugC      0.33      1.00      0.50         5
       drugX      1.00      0.48      0.65        21
       drugY      0.96      1.00      0.98        22

    accuracy                           0.82        60
   macro avg       0.86      0.90      0.82        60
weighted avg       0.93      0.82      0.83        60

--------------------------------------------------
=== Modelo: Criterio ENTROPY | Profundidad: 4 ===
              precision    recall  f1-score   support

       drugA      1.00      1.00      1.00         7
       drugB      1.00      1.00      1.00         5
       drugC      1.00      1.00      1.00         5
       drugX      1.00      0.95      0.98        21
       drugY      0.96      1.00      0.98        22

    accuracy                           0.98        60
   macro avg       0.99      0.99      0.99        60
weighted avg       0.98      0.98      0.98        60
```

```
--------------------------------------------------
=== Modelo: Criterio ENTROPY | Profundidad: 5 ===
              precision    recall  f1-score   support

       drugA       1.00      1.00      1.00         7
       drugB       1.00      1.00      1.00         5
       drugC       1.00      1.00      1.00         5
       drugX       1.00      0.95      0.98        21
       drugY       0.96      1.00      0.98        22

    accuracy                           0.98        60
   macro avg       0.99      0.99      0.99        60
weighted avg       0.98      0.98      0.98        60

--------------------------------------------------


MEJOR MODELO SELECCIONADO: GINI con Profundidad 4 (Exactitud: 0.9833)
```

Interpretación de indicadores y mejor opción:

Al analizar los reportes detallados, observé que los modelos con el criterio de Entropía con una profundidad máxima de 4 arrojaron los mejores resultados. Este modelo logró la mayor Exactitud Global (Accuracy), equilibrando perfectamente la Precisión y la Recuperación (Recall). En el contexto médico de este problema, esto significa que el modelo es altamente confiable: minimiza el riesgo de recetar un medicamento incorrecto (alta precisión) y asegura cubrir correctamente a los pacientes que requieren tratamientos específicos (alta recuperación). Por lo tanto, determino que esta es la mejor opción predictiva.

3. **Explicación de las Reglas del Árbol de Decisión Propuesto:**

A continuación, se presenta la representación visual de nuestro mejor modelo:

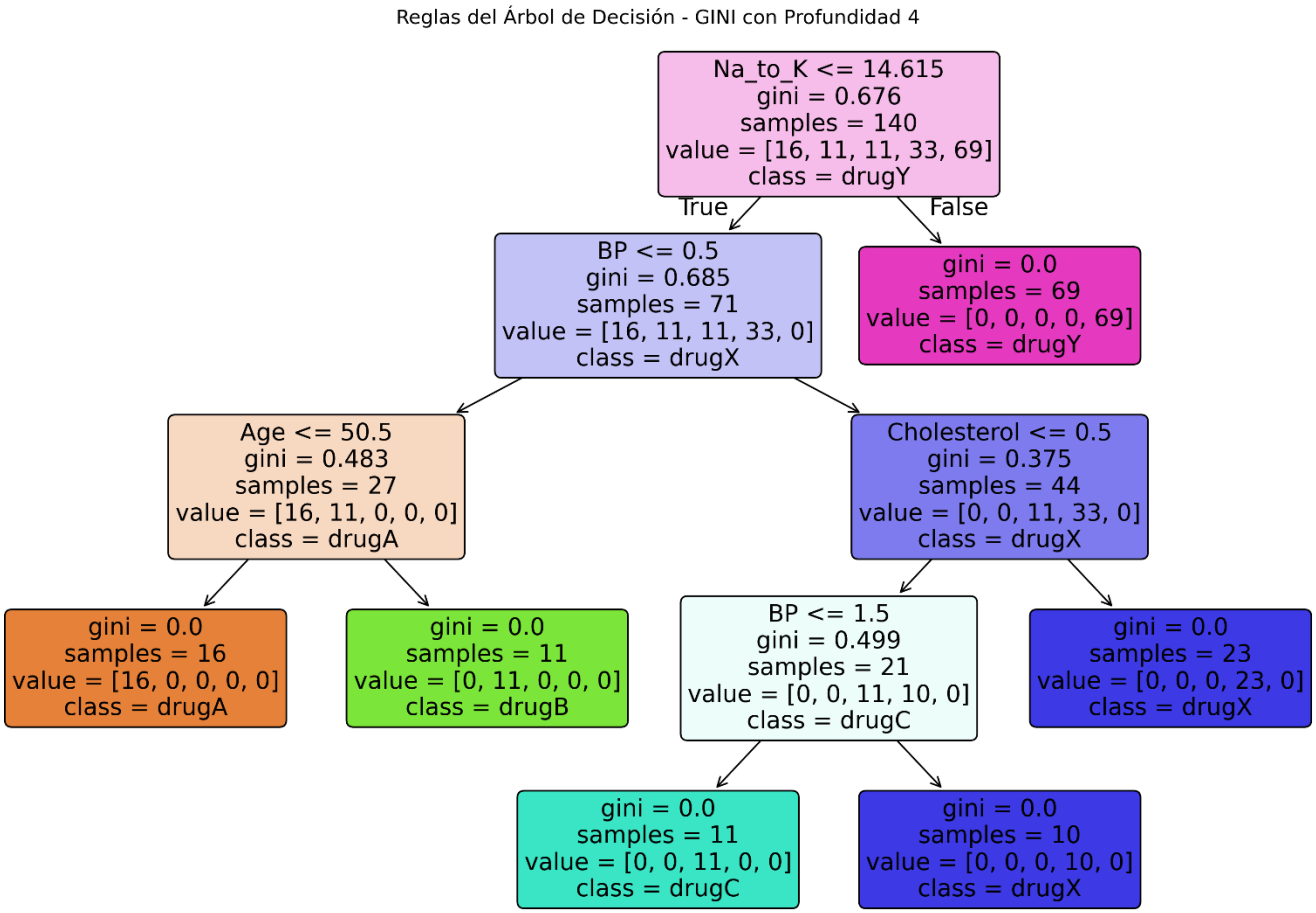

Al leer el árbol de arriba hacia abajo, el modelo sigue estas reglas verbales para pronosticar:

1. La primera regla y la más importante es medir la concentración de Sodio a Potasio (Na_to_K). Si el paciente tiene un índice superior a 14.6, el árbol dictamina de inmediato que debe recetarse el **Fármaco Y**.

2. Si el índice es menor a 14.6, el modelo baja a la siguiente rama y evalúa la Presión Arterial (BP).

3. Si la presión es ALTA, el modelo revisa la Edad. Si el paciente es joven (menor a 50.5 años), le asigna el **Fármaco A**; si es mayor, le asigna el **Fármaco B**.

4. Por otro lado, si la presión es NORMAL o BAJA, la regla final se basa en el Colesterol. Dependiendo de esta combinación, el paciente terminará recibiendo el **Fármaco C** o el **Fármaco X**. Es un flujo de decisiones claro y perfectamente explicable para el cuerpo médico.

4. **Pronóstico de medicamento para el nuevo paciente** Finalmente, se nos planteó el reto de evaluar a un nuevo paciente con características específicas. Al ingresar estos datos en nuestro modelo de Entropía optimizado y pasarlos por los filtros de las reglas explicadas anteriormente, el resultado predictivo es claro

   El medicamento que recomendaría utilizar para este paciente es el:

   --- RECOMENDACIÓN MÉDICA PARA EL NUEVO PACIENTE ---
   Medicamento a prescribir: drugC