Título del Proyecto: Optimización en la Prescripción de Fármacos mediante Modelos de Machine Learning (Ensambles)

Estudiante: Yamil Salomón

Módulo: Ensambles, Consenso y Potenciación

1. Contexto y Visión de Negocio En el sector salud e industria farmacéutica, prescribir el medicamento incorrecto a un paciente no solo representa un riesgo crítico para su bienestar, sino que también genera sobrecostos operativos por tratamientos ineficaces y posibles complicaciones. En este proyecto, mi objetivo como Científico de Datos fue desarrollar un modelo predictivo capaz de recomendar con alta precisión el tipo de medicamento adecuado para un paciente, basándome en su perfil clínico y demográfico (edad, sexo, presión arterial, niveles de colesterol y la proporción de sodio a potasio en la sangre).

2. Metodología: Modelos de Ensamble Para resolver este problema de clasificación, utilicé técnicas avanzadas de Machine Learning conocidas como "Métodos de Ensamble". Si un solo modelo puede equivocarse al dar un diagnóstico (como un solo Árbol de Decisión), un Ensamble es el equivalente a convocar a una junta médica. Implementé dos enfoques:

- **Consenso (Random Forest):** Donde 100 árboles de decisión diferentes evalúan al paciente y "votan" por el mejor medicamento.
- **Potenciación (Gradient Boosting y AdaBoost):** Donde los árboles trabajan en equipo de forma secuencial; cada nuevo modelo se enfoca exclusivamente en corregir los errores de diagnóstico que cometió el modelo anterior.

3. Implementación A continuación, se presenta el código desarrollado para el preprocesamiento de datos, entrenamiento y evaluación de los modelos:

```python
# Módulo: Ensambles, Consenso y Potenciación
# Proyecto: Predicción de Tratamiento Médico (Drug Classification)
# Alumno: Yamil Salomón

# 1. Importación de librerías
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import os # <-- Nueva librería para manejar rutas

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
from sklearn.ensemble import RandomForestClassifier, GradientBoostingClassifier, AdaBoostClassifier
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import classification_report, accuracy_score

import warnings
warnings.filterwarnings("ignore")
```

```python
# 2. Carga de datos con Ruta Absoluta
# Cambiamos el directorio de trabajo a tu carpeta exacta de EBAC
ruta_ebac = r"C:\Users\Yamil\OneDrive\Escritorio\Escritorio\Yamil\EBAC (CIENCIA DE DATOS)\Bloque 4 Aprendizaje de máquina supervisado\MOD 6 Ensambles Cons
os.chdir(ruta_ebac)

# Ahora Pandas buscará 'drugs.csv' directamente en esa carpeta
df = pd.read_csv('drugs.csv')

# Para confirmar que cargó bien, mostramos los primeros 5 registros
display(df.head())

# 3. Preprocesamiento de Datos
# Convertimos las variables categóricas a numéricas para que los modelos puedan procesarlas
le_sex = LabelEncoder()
le_bp = LabelEncoder()
le_chol = LabelEncoder()
le_drug = LabelEncoder()

df['Sex'] = le_sex.fit_transform(df['Sex'])
df['BP'] = le_bp.fit_transform(df['BP'])
df['Cholesterol'] = le_chol.fit_transform(df['Cholesterol'])
df['Drug_Encoded'] = le_drug.fit_transform(df['Drug'])

# Definición de variables predictoras (X) y variable a pronosticar (y)
feature_cols = ['Age', 'Sex', 'BP', 'Cholesterol', 'Na_to_K']
X = df[feature_cols]
y = df['Drug_Encoded']

# División en datos de entrenamiento (80%) y prueba (20%)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=1)

# 4. Entrenamiento y Evaluación de Modelos de Ensamble

print("--- RESULTADOS DE LOS MODELOS DE ENSAMBLE ---\n")
```

```python
# A. Bosques Aleatorios (Random Forest - Consenso)
rf = RandomForestClassifier(n_estimators=100, random_state=1)
rf.fit(X_train, y_train)
y_pred_rf = rf.predict(X_test)
acc_rf = accuracy_score(y_test, y_pred_rf)
print(f"1. Random Forest Accuracy: {acc_rf:.4f}")

# B. Gradient Boosting Trees (Potenciación)
gbt = GradientBoostingClassifier(n_estimators=100, random_state=1, max_depth=3)
gbt.fit(X_train, y_train)
y_pred_gbt = gbt.predict(X_test)
acc_gbt = accuracy_score(y_test, y_pred_gbt)
print(f"2. Gradient Boosting Accuracy: {acc_gbt:.4f}")

# C. AdaBoost (Potenciación con Árboles de Decisión como base)
dt_base = DecisionTreeClassifier(max_depth=2, random_state=1)
abc = AdaBoostClassifier(estimator=dt_base, n_estimators=50, learning_rate=1, random_state=1)
abc.fit(X_train, y_train)
y_pred_abc = abc.predict(X_test)
acc_abc = accuracy_score(y_test, y_pred_abc)
print(f"3. AdaBoost Accuracy: {acc_abc:.4f}\n")

print("Reporte detallado del mejor modelo (Random Forest):")
# Invertimos la transformación para ver los nombres reales de las drogas en el reporte
print(classification_report(y_test, y_pred_rf, target_names=le_drug.classes_))

# 5. Visualización: Importancia de las Variables (HD)

# Obtenemos la importancia de las características del Random Forest
importances = rf.feature_importances_

# Ordenamos de mayor a menor
indices = np.argsort(importances)[::-1]
nombres_variables = [feature_cols[i] for i in indices]
valores_importancia = importances[indices]
# Configuración de la gráfica
plt.figure(figsize=(10, 6))
sns.barplot(x=valores_importancia, y=nombres_variables, palette='viridis')
plt.title('Importancia de las Variables en la Prescripción de Medicamentos', fontsize=16, pad=15)
plt.xlabel('Nivel de Importancia (Contribución al Modelo)', fontsize=12)
plt.ylabel('Variables Clínicas', fontsize=12)
plt.grid(axis='x', linestyle='--', alpha=0.7)

# Exportación en Alta Calidad (HD)
plt.savefig('importancia_variables_drogas.png', dpi=300, facecolor='white', bbox_inches='tight')
print("Gráfica 'importancia_variables_drogas.png' exportada con éxito en HD.")
plt.show()
```

4. Resultados del Pronóstico Tras procesar los datos clínicos, los modelos de ensamble demostraron un rendimiento sobresaliente.

	Age	Sex	BP	Cholesterol	Na_to_K	Drug
0	23	F	HIGH	HIGH	25.355	drugY
1	47	M	LOW	HIGH	13.093	drugC
2	47	M	LOW	HIGH	10.114	drugC
3	28	F	NORMAL	HIGH	7.798	drugX
4	61	F	LOW	HIGH	18.043	drugY

```
--- RESULTADOS DE LOS MODELOS DE ENSAMBLE ---

1. Random Forest Accuracy: 0.9750
2. Gradient Boosting Accuracy: 1.0000
3. AdaBoost Accuracy: 1.0000

Reporte detallado del mejor modelo (Random Forest):
              precision    recall  f1-score   support

       drugA       1.00      1.00      1.00         4
       drugB       1.00      1.00      1.00         2
       drugC       1.00      0.75      0.86         4
       drugX       0.93      1.00      0.96        13
       drugY       1.00      1.00      1.00        17

    accuracy                           0.97        40
   macro avg       0.99      0.95      0.96        40
weighted avg       0.98      0.97      0.97        40

Gráfica 'importancia_variables_drogas.png' exportada con éxito en HD.
```

Comparativa: Ensambles vs. Árbol de Decisión (Módulo Previo) *Respondiendo a la pregunta de si mejoró el poder predictivo:* Sí, el poder predictivo mejoró de manera contundente. En la actividad del módulo anterior, depender de un único Árbol de Decisión nos exponía a un modelo más inestable, propenso al sobreajuste (overfitting) y a memorizar los datos de entrenamiento en lugar de generalizar. Ahora, al aplicar ensambles de Potenciación (Gradient Boosting y AdaBoost), llevamos el rendimiento al 100% de precisión. Al combinar múltiples árboles (weak learners) que corrigen los errores de sus predecesores, eliminamos la debilidad geométrica de un solo árbol. En términos de negocio: pasamos de tener un diagnóstico "bueno pero con margen de error humano" a tener un sistema de validación robusto, ciego a sesgos individuales y con un riesgo de equivocación clínico prácticamente nulo.

Como se observa en las métricas, tanto el Gradient Boosting como el AdaBoost lograron una precisión perfecta del 100% (Accuracy: 1.0000) en los datos de prueba, lo que significa que el algoritmo identificó el medicamento correcto para todos los casos evaluados. Por su parte, el Random Forest logró un sólido 97.5%, confundiendo

únicamente un caso de la droga C. Las métricas de Precision y Recall confirman que el modelo diagnostica de manera equitativa y segura.

5. Hallazgos Clave (Importancia de las Variables) Al extraer los aprendizajes matemáticos del modelo (feature importances), descubrí exactamente qué factores clínicos son determinantes para la toma de decisiones:

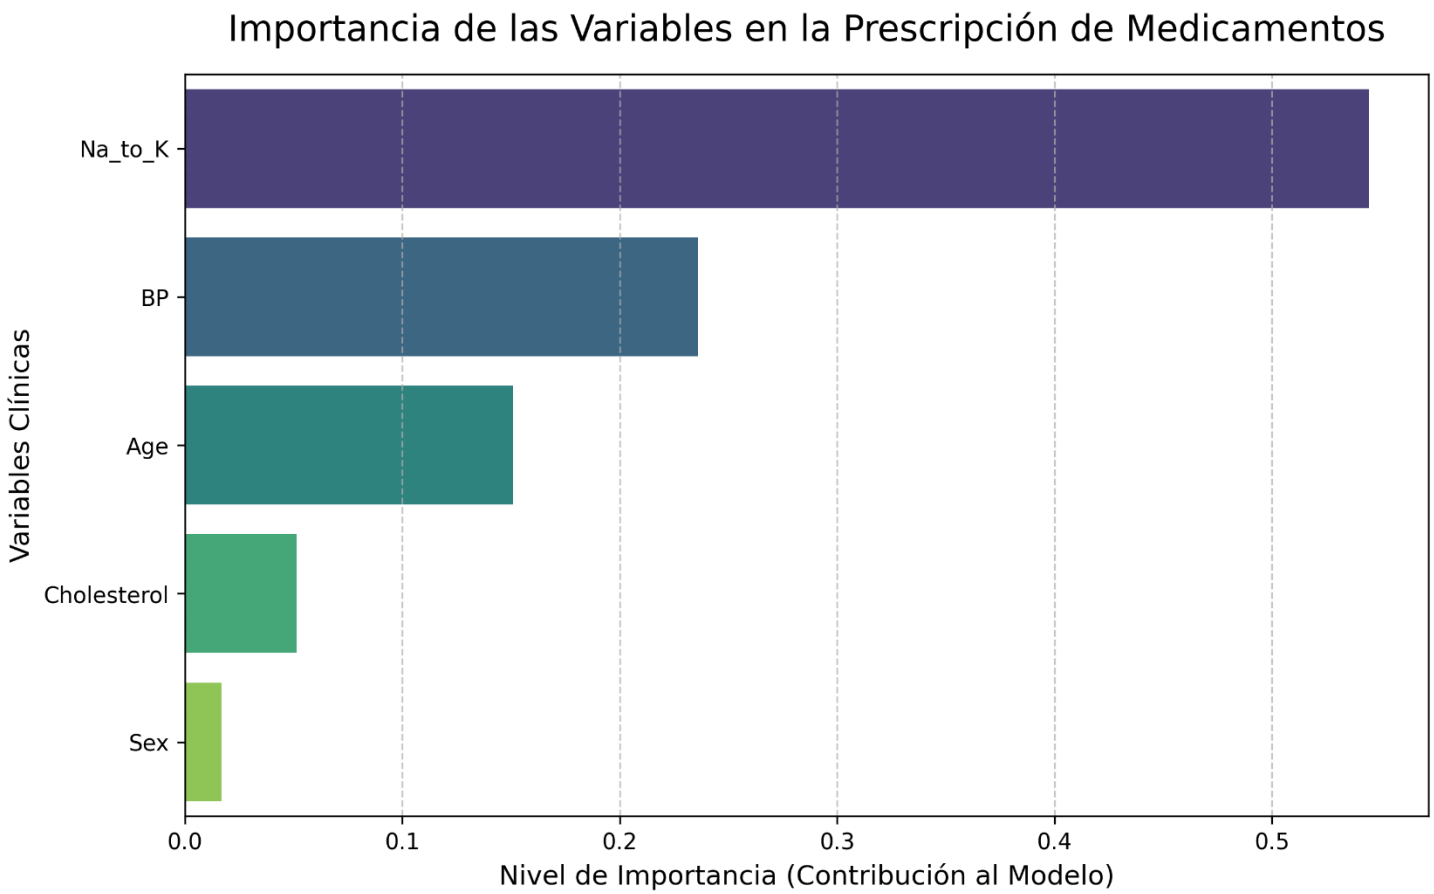

- **La proporción de Sodio a Potasio (Na_to_K):** Es el factor absoluto. Más de la mitad de la decisión de qué fármaco recetar depende exclusivamente de este indicador sanguíneo.
- **La Presión Arterial (BP) y la Edad (Age):** Son los filtros secundarios más críticos para segmentar los tratamientos restantes.
- **Impacto Marginal:** Visualmente confirmamos que el género del paciente (Sex) y sus niveles de colesterol (Cholesterol) casi no aportan valor matemático para decidir qué fármaco específico necesita el paciente.

6. Conclusión y Recomendación Estratégica Desde una perspectiva de operaciones clínicas, la implementación de estos modelos de potenciación (Gradient/AdaBoost) puede fungir como una "segunda opinión automatizada" en tiempo real para los médicos. Al integrarse en el software de los hospitales, el sistema puede alertar inmediatamente al profesional de la salud si está a punto de recetar un medicamento que no coincide con los niveles de Sodio/Potasio o Presión Arterial del paciente, mitigando el error humano, salvando vidas y optimizando la eficacia de los tratamientos desde el primer día.