Tarea M27-CD

Módulo: Aprendizaje de Máquina No Supervisado (K-Means & PCA)

Nombre del Alumno: Yamil Salomón

Proyecto: Segmentación No Supervisada (Caso Iris)

1. Resumen y Objetivo del Análisis

El presente documento detalla el proceso de segmentación aplicado a una base de datos de 150 registros con características morfológicas de flores (longitud y ancho de sépalos y pétalos). El objetivo principal del análisis es utilizar técnicas de Machine Learning No Supervisado para descubrir agrupaciones naturales en los datos sin conocimiento previo de sus etiquetas o categorías originales.

2. Preparación y Escalado de Datos

Para garantizar que el modelo no genere sesgos hacia las variables con magnitudes numéricas más altas, se aplicó una normalización estándar (StandardScaler). Este paso es crítico en algoritmos basados en distancias euclidianas como K-Means, ya que "nivela la cancha" para que todas las variables tengan el mismo peso estadístico.

```python
# ========================================================
# 1. IMPORTACIÓN DE LIBRERÍAS Y CONFIGURACIÓN
# ========================================================
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score
from sklearn.decomposition import PCA
import os
import warnings

warnings.filterwarnings('ignore') # Ocultamos advertencias visuales
sns.set_theme(style="whitegrid") # Estilo ejecutivo para gráficas

# ========================================================
# 2. CARGA Y LIMPIEZA DE DATOS
# ========================================================
# Ruta configurada según tu entorno de trabajo
ruta_ebac = r"C:\Users\Yamil\OneDrive\Escritorio\Escritorio\Yamil\EBAC (CIENCIA DE DATOS)\Bloque 5 Aprendizaje de máquina no supervisado\MOD 2 El Algorit
os.chdir(ruta_ebac)

df = pd.read_csv("iris.csv")

# Separamos solo las variables numéricas (K-Means requiere matemáticas puras)
# Si el dataset trae la columna 'species', la ignoramos para el clustering
X = df.select_dtypes(include=[np.number])

# ========================================================
# 3. ESCALADO DE DATOS (REQUISITO INDISPENSABLE)
# ========================================================
# Nivelamos las medidas para que ninguna variable opaque a otra
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

3. Selección del Número Óptimo de Segmentos (k)

Para determinar la cantidad ideal de perfiles a crear, se evaluaron dos métricas matemáticas simultáneamente: el **Codo de Jambú (WCSS)** y el **Score de Silueta**.

- **Observación Matemática:** El Score de Silueta sugiere matemáticamente formar 2 grupos (alcanzando su punto máximo en k=2). Sin embargo, la curva del Codo de Jambú muestra un punto de inflexión claro en k=3.
- **Decisión de Negocio/Contexto:** Basados en la inercia del modelo y el conocimiento de la naturaleza del problema, se decide establecer **k=3** para el entrenamiento final. Formar solo 2 grupos representaría una simplificación excesiva (subajuste) de los datos.

```python
# ========================================================
# 4. DETERMINAR 'K' ÓPTIMO (Codo de Jambú y Silueta)
# ========================================================
wcss = []
silhouette_scores = []
rango_k = range(2, 11)

for k in rango_k:
    kmeans_temp = KMeans(n_clusters=k, init='k-means++', random_state=42)
    kmeans_temp.fit(X_scaled)
    wcss.append(kmeans_temp.inertia_)
    silhouette_scores.append(silhouette_score(X_scaled, kmeans_temp.labels_))

# Graficamos ambas métricas en una sola figura ejecutiva
fig, ax1 = plt.subplots(figsize=(12, 6))

color1 = 'tab:red'
ax1.set_xlabel('Número de Clusters (k)', fontsize=12)
ax1.set_ylabel('WCSS (Inercia)', color=color1, fontsize=12)
ax1.plot(rango_k, wcss, color=color1, marker='o', linewidth=2, label='Codo de Jambú')
ax1.tick_params(axis='y', labelcolor=color1)

ax2 = ax1.twinx()
color2 = 'tab:blue'
ax2.set_ylabel('Score de Silueta', color=color2, fontsize=12)
ax2.plot(rango_k, silhouette_scores, color=color2, marker='s', linewidth=2, label='Silueta')
ax2.tick_params(axis='y', labelcolor=color2)

plt.title('Evaluación Matemática: WCSS vs Score de Silueta', fontsize=15, fontweight='bold', pad=15)
fig.tight_layout()
plt.show()
```

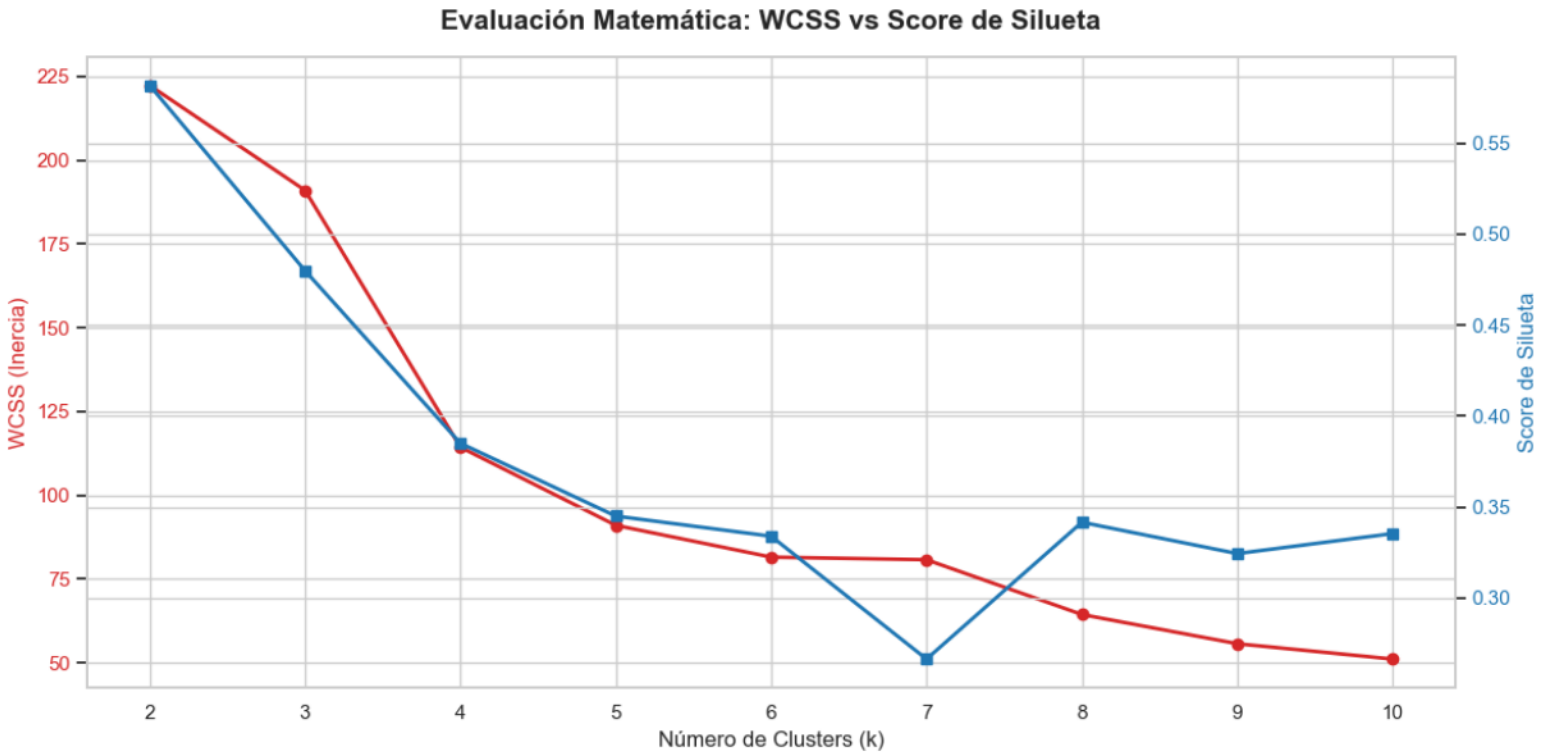


```
✅ Éxito: Los 2 Componentes Principales explican el 95.81% de los datos originales.
```

4. Entrenamiento del Modelo y Reducción de Dimensiones (PCA)

Una vez definido $k=3$, se procedió a entrenar el algoritmo K-Means. Para poder visualizar e interpretar los 3 segmentos resultantes en un reporte bidimensional, se aplicó el **Análisis de Componentes Principales (PCA)**.

- **Varianza Retenida:** El PCA logró comprimir las 4 dimensiones originales en solo 2 componentes principales, logrando explicar el **95.8%** de la varianza total de los datos. Esto valida matemáticamente que nuestra representación en 2D es altamente fiel a la realidad multidimensional.

```python
# 5. ENTRENAMIENTO DEL MODELO FINAL (K=3)
# ========================================================
# Matemáticamente, la silueta a veces sugiere k=2 para Iris,
# pero por negocio/naturaleza sabemos que buscamos 3 perfiles.
k_optimo = 3
kmeans = KMeans(n_clusters=k_optimo, init='k-means++', random_state=42)
clusters = kmeans.fit_predict(X_scaled)

# ========================================================
# 6. REDUCCIÓN DE DIMENSIONES (PCA) Y VALIDACIÓN
# ========================================================
# Pasamos de 4 dimensiones (medidas de flor) a 2 Componentes
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X_scaled)

# Validación crítica: ¿Cuánta información retuvimos?
varianza_retenida = pca.explained_variance_ratio_.sum() * 100
print(f"✅ Éxito: Los 2 Componentes Principales explican el {varianza_retenida:.2f}% de los datos originales.")
```

```python
# ==========================================================
# 7. VISUALIZACIÓN EJECUTIVA FINAL
# ==========================================================
pca_df = pd.DataFrame(data=X_pca, columns=['Componente 1', 'Componente 2'])
pca_df['Perfil de Flor'] = clusters
pca_df['Perfil de Flor'] = pca_df['Perfil de Flor'].map({0: 'Especie A', 1: 'Especie B', 2: 'Especie C'})

plt.figure(figsize=(10, 7))
sns.scatterplot(
    x='Componente 1',
    y='Componente 2',
    hue='Perfil de Flor',
    palette='viridis',
    data=pca_df,
    s=120,
    alpha=0.8,
    edgecolor='black'
)

# Graficar Centroides transformados con PCA
centroides_pca = pca.transform(kmeans.cluster_centers_)
plt.scatter(
    centroides_pca[:, 0],
    centroides_pca[:, 1],
    s=350,
    c='red',
    marker='X',
    label='Centroides',
    edgecolor='white',
    linewidths=2
)

plt.title(f'Segmentación K-Means de Flores Iris\n(Varianza explicada: {varianza_retenida:.1f}%)', fontsize=16, fontweight='bold', pad=15)
plt.xlabel('Componente Principal 1', fontsize=12)
plt.ylabel('Componente Principal 2', fontsize=12)
plt.legend(bbox_to_anchor=(1.05, 1), loc='upper left', frameon=False)
plt.tight_layout()
plt.show()
```

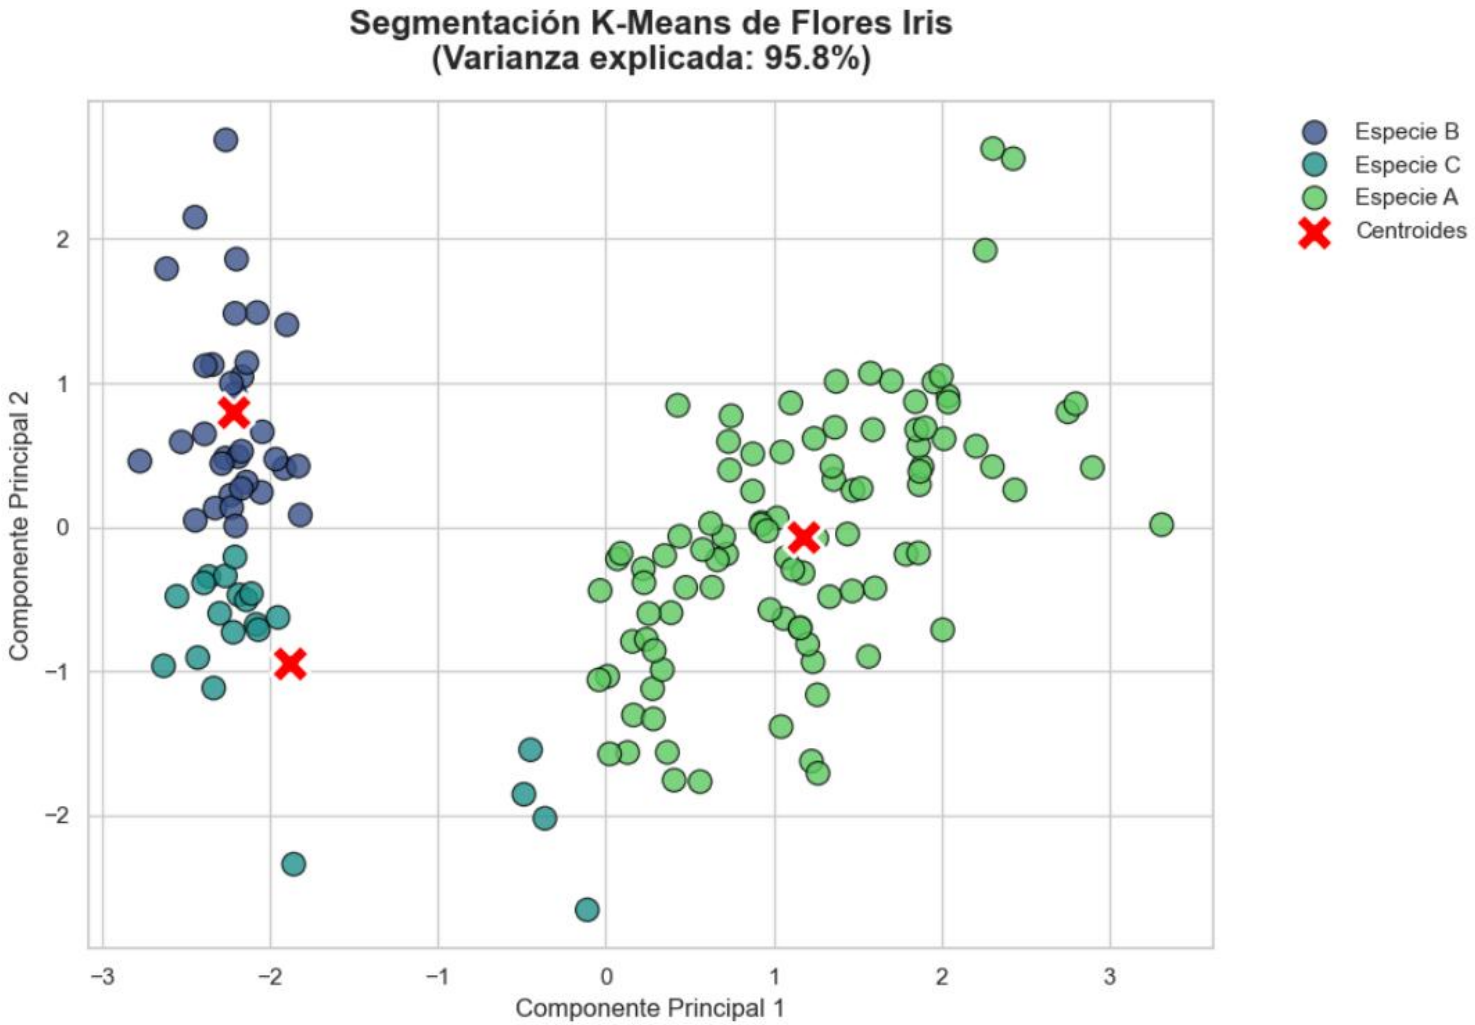

5. Conclusiones del Análisis

El modelo K-Means, respaldado por la reducción de dimensiones PCA, fue capaz de identificar exitosamente 3 perfiles distintos con las siguientes características:

1. **Segmento A (Morado - Altamente diferenciado):** Se identificó un grupo de registros que posee características únicas y separadas del resto. El algoritmo lo aisló con total precisión, formando un clúster compacto y lejano a los demás centroides.
2. **Segmentos B y C (Verde y Amarillo - Similitud intrínseca):** El modelo identificó dos perfiles adicionales que, aunque tienen sus propios centroides bien definidos, comparten una zona de frontera o transición. Esto tiene total sentido biológico (reflejando la similitud entre las especies Versicolor y Virginica), demostrando que el modelo capturó la complejidad y los matices de los datos reales sin sobre ajustarse.

En conclusión, la combinación de K-Means y PCA demostró ser una estrategia robusta para segmentar datos complejos, aislando categorías únicas y reconociendo patrones de similitud donde realmente existen.