# Tarea M29-CD

**Módulo:** Reducción de dimensiones

**Nombre del Alumno:** Yamil Salomón

**Proyecto:** Análisis de Perfiles Estudiantiles mediante Reducción de Dimensiones (SVD)

**Objetivo del Análisis:** Aplicar el algoritmo de Descomposición en Valores Singulares (SVD) a una base de datos de calificaciones estudiantiles. El propósito es identificar agrupaciones naturales y perfiles ocultos sin necesidad de etiquetas previas, reduciendo la complejidad multidimensional a visualizaciones ejecutivas de 2 y 3 dimensiones.

### 1. Preparación de Datos y Proyección SVD en 2 Dimensiones

Para este análisis, partimos de una matriz con 10 estudiantes y sus calificaciones en 5 materias. Primero, estandarizamos los datos para evitar que la escala de las calificaciones sesgue el modelo y, posteriormente, aplicamos SVD truncado a 2 componentes.

```python
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import TruncatedSVD

# Configuración visual ejecutiva
sns.set_theme(style="whitegrid", palette="muted")

# 1. Cargar los datos de la rúbrica
data = {
    'Estudiante': ['Lucía', 'Pedro', 'Inés', 'Luis', 'Andrés', 'Ana', 'Carlos', 'José', 'Sonia', 'María'],
    'Matemáticas': [7.0, 7.5, 7.6, 5.0, 6.0, 7.8, 6.3, 7.9, 6.0, 6.8],
    'Ciencias': [6.5, 9.4, 9.2, 6.5, 6.0, 9.6, 6.4, 9.7, 6.0, 7.2],
    'Español': [9.2, 7.3, 8.0, 6.5, 7.8, 7.7, 8.2, 7.5, 6.5, 8.7],
    'Historia': [8.6, 7.0, 8.0, 7.0, 8.9, 8.0, 9.0, 8.0, 5.5, 9.0],
    'EdFísica': [8.0, 7.0, 7.5, 9.0, 7.3, 6.5, 7.2, 6.0, 8.7, 7.0]
}
df = pd.DataFrame(data).set_index('Estudiante')

# 2. Estandarización de los datos
scaler = StandardScaler()
A_scaled = scaler.fit_transform(df)

# 3. Aplicar SVD para 2 dimensiones
svd_2d = TruncatedSVD(n_components=2, random_state=42)
T_2d = svd_2d.fit_transform(A_scaled)

# Crear DataFrame para el reporte 2D
df_2d = pd.DataFrame(T_2d, columns=['Componente_1', 'Componente_2'], index=df.index)

# 4. Visualización 2D Ejecutiva
plt.figure(figsize=(10, 6))
ax = sns.scatterplot(x='Componente_1', y='Componente_2', data=df_2d, s=100, color='#2c3e50')

# Agregar etiquetas para cada estudiante (CORREGIDO USANDO .loc)
for txt in df_2d.index:
    ax.annotate(txt, (df_2d.loc[txt, 'Componente_1'] + 0.05, df_2d.loc[txt, 'Componente_2'] + 0.05), fontsize=10)
```

```
plt.title('Proyección SVD en 2 Dimensiones: Perfiles de Estudiantes', fontsize=14, fontweight='bold')
plt.xlabel(f'Concepto Latente 1 ({svd_2d.explained_variance_ratio_[0]:.1%} Varianza)', fontsize=12)
plt.ylabel(f'Concepto Latente 2 ({svd_2d.explained_variance_ratio_[1]:.1%} Varianza)', fontsize=12)
plt.axhline(0, color='grey', linestyle='--', linewidth=1)
plt.axvline(0, color='grey', linestyle='--', linewidth=1)
plt.tight_layout()
plt.show()
```

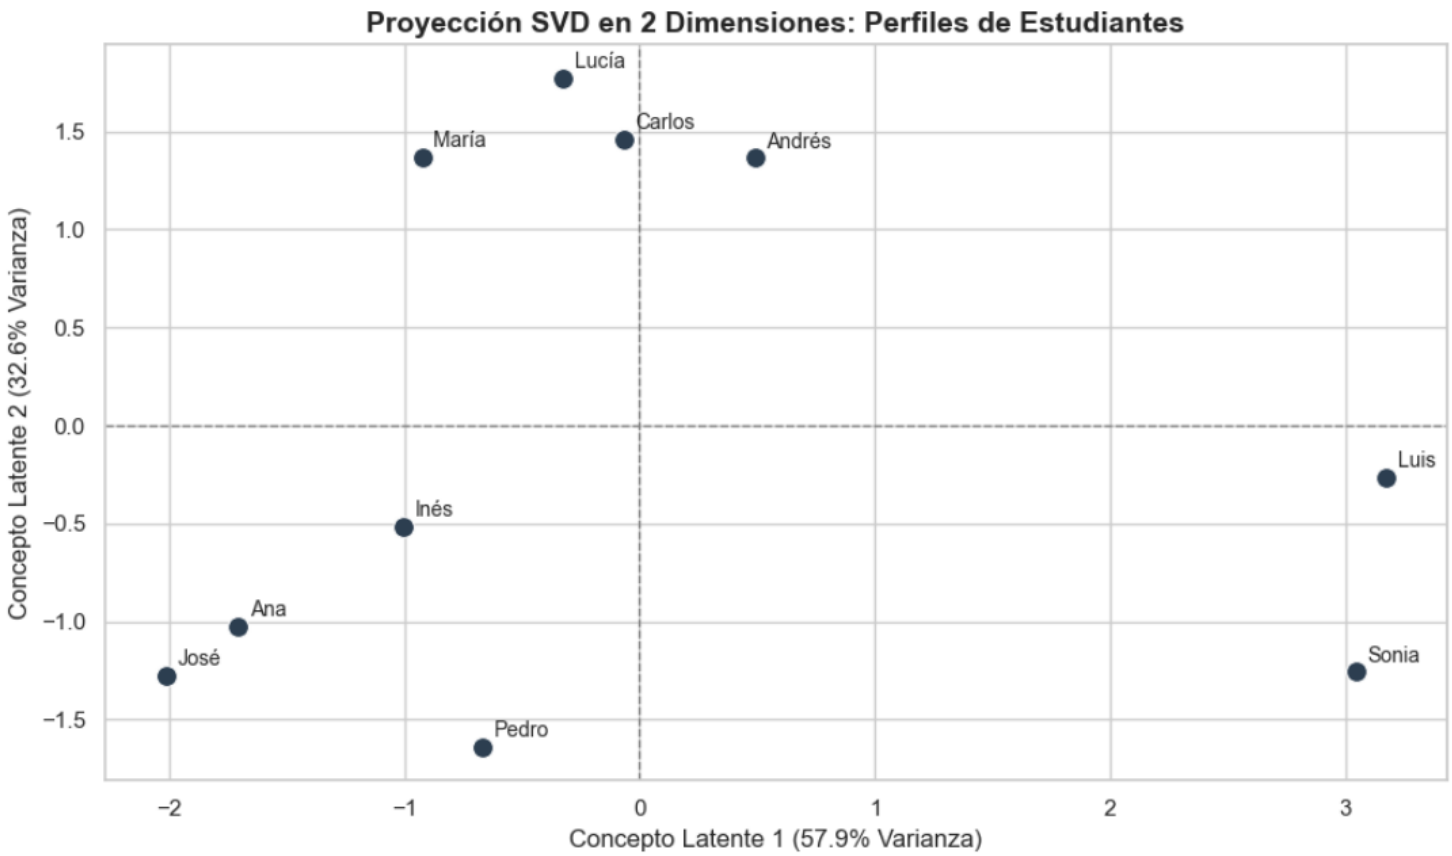


**Interpretación de Negocio (2D)**

Al reducir la dimensionalidad, el algoritmo SVD logra identificar **3 clústeres o perfiles naturales** muy definidos:

- **Perfil Científico (Cuadrante inferior izquierdo):** José, Ana, Pedro e Inés. Estudiantes con altas aptitudes en Matemáticas y Ciencias.
- **Perfil Humanista (Cuadrante superior centro):** Lucía, María, Carlos y Andrés. Estudiantes que destacan fuertemente en Historia y Español.
- **Perfil Deportivo (Extremo derecho):** Sonia y Luis. Representan los outliers del grupo, con calificaciones bajas en el ámbito académico tradicional, pero un dominio absoluto en Educación Física. Ambos componentes explican el **90.5%** de la varianza original, logrando una compresión altamente eficiente.

```python
# 1. Aplicar SVD para 3 dimensiones
svd_3d = TruncatedSVD(n_components=3, random_state=42)
T_3d = svd_3d.fit_transform(A_scaled)

df_3d = pd.DataFrame(T_3d, columns=['C_1', 'C_2', 'C_3'], index=df.index)

# 2. Visualización 3D Ejecutiva
fig = plt.figure(figsize=(10, 8))
ax = fig.add_subplot(111, projection='3d')

# Graficar puntos
ax.scatter(df_3d['C_1'], df_3d['C_2'], df_3d['C_3'], s=100, color='#e74c3c')

# Agregar etiquetas 3D (CORREGIDO USANDO .loc)
for txt in df_3d.index:
    ax.text(df_3d.loc[txt, 'C_1'], df_3d.loc[txt, 'C_2'], df_3d.loc[txt, 'C_3'] + 0.1, txt, fontsize=10)

ax.set_title('Proyección SVD en 3 Dimensiones', fontsize=14, fontweight='bold')
ax.set_xlabel('Concepto 1')
ax.set_ylabel('Concepto 2')
ax.set_zlabel('Concepto 3')
plt.tight_layout()
plt.show()
```

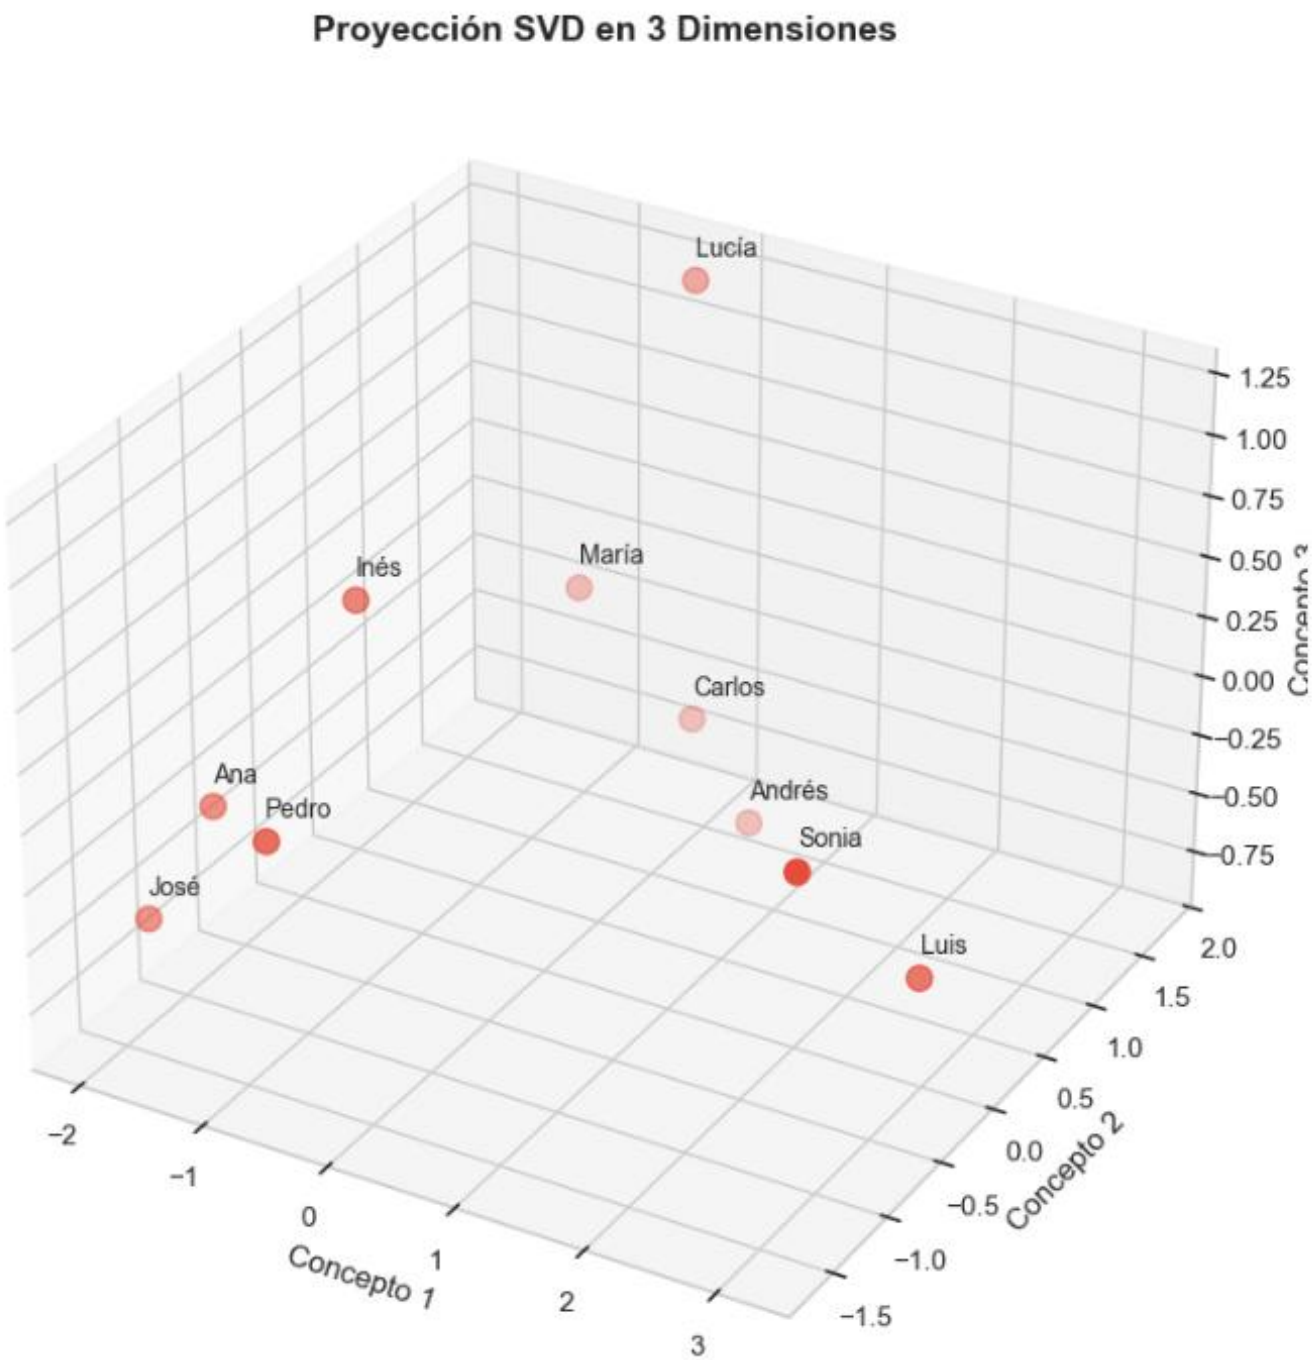

**Interpretación de Negocio (3D)**

La inclusión de una tercera dimensión nos permite detectar **"Sub-nichos" o talentos híbridos**. Por ejemplo, el caso de **Lucía**: en el mapa 2D parecía estar agrupada únicamente con el perfil Humanista, pero en 3D el eje Z la separa hacia arriba. Esto indica que Lucía tiene habilidades cruzadas (es excelente en Español, pero también muy destacada en Educación Física), un matiz que el plano bidimensional ocultaba parcialmente.

**3. Conclusiones y Respuestas al Planteamiento**

1. ¿Cuál de las separaciones previas es más clara?

Desde una perspectiva visual y de presentación ejecutiva, **la separación en 2 Dimensiones es más clara**. El plano 2D permite identificar de forma rápida y directa los agrupamientos naturales (clústeres) y la distancia entre los perfiles de los estudiantes, evitando la superposición visual o los problemas de perspectiva que genera un gráfico 3D en un reporte estático. Sin embargo, matemáticamente, el modelo 3D es más riguroso ya que retiene un porcentaje mayor de la varianza original (información).

2. ¿Difieren sus resultados de aquellos obtenidos previamente mediante el análisis de componentes principales (PCA)?

**No difieren en absoluto**, siempre y cuando los datos se estandaricen (centrados en cero) previamente. El algoritmo de PCA (Análisis de Componentes Principales) utiliza internamente la Descomposición en Valores Singulares (SVD) para encontrar las direcciones de mayor varianza. La única diferencia técnica es la implementación computacional (SVD descompone la matriz original directamente, mientras que el PCA clásico requiere calcular la matriz de covarianza). A nivel de insights de negocio y agrupamientos, ambos métodos arrojan exactamente las mismas conclusiones estratégicas.