Tarea M28-CD

Módulo: Reducción de dimensiones

Nombre del Alumno: Yamil Salomón

Proyecto: Análisis de Componentes Principales (PCA) - Caso Iris

1. Metodología Aplicada

Para garantizar la integridad matemática del modelo, se ejecutó el siguiente pipeline de datos:

- **Estandarización de Escalas:** Se aplicó StandardScaler para equilibrar el peso de todas las variables (largo y ancho de sépalos/pétalos) y evitar que las medidas más grandes dominaran artificialmente el modelo.
- **Reducción de Dimensionalidad:** Se implementó el algoritmo PCA para extraer las dos direcciones de máxima varianza (Componentes Principales).

2. Implementación Técnica (Código en Python)

A continuación, se presenta el código modular utilizado para la transformación matemática y la generación del DataFrame estructurado:

```python
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA

# 1. Carga de datos (Usando tu ruta exacta)
ruta_archivo = r"C:\Users\Yamil\OneDrive\Escritorio\Escritorio\Yamil\EBAC (CIENCIA DE DATOS)\Bloque 5 Aprendizaje de máquina no supervisado\MOD 3 Reducci
df_iris = pd.read_csv(ruta_archivo)

# 2. Separación de características (X) y variable objetivo (y)
# Tomamos todas las columnas excepto la última como 'X', y la última como nuestro 'Target'
X = df_iris.iloc[:, :-1]
y = df_iris.iloc[:, -1]

# 3. Estandarización de los datos (Regla de Oro del PCA)
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# 4. Reducción de Dimensiones con PCA
# Forzamos al algoritmo a darnos solo 2 componentes principales
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X_scaled)

# 5. Construcción del DataFrame (Idéntico a la rúbrica)
df_pca = pd.DataFrame(data=X_pca, columns=['Componente 1', 'Componente 2'])
df_pca['Target'] = y.values

# Mostramos las primeras filas para validar contra tu imagen de ejemplo
print("--- Vista previa del DataFrame ---")
print(df_pca.head())
print("\n")
```

```python
# --- VISUALIZACIÓN EJECUTIVA ---
# Configuración de estilo limpio para reportes
plt.figure(figsize=(10, 6))
sns.set_theme(style="whitegrid")

# Gráfico de dispersión
sns.scatterplot(
    x='Componente 1',
    y='Componente 2',
    hue='Target',
    data=df_pca,
    palette='viridis', # Paleta de colores profesional
    s=100,             # Tamaño de los puntos
    alpha=0.8,         # Transparencia para ver puntos superpuestos
    edgecolor='w'      # Borde blanco para mayor nitidez
)

# Títulos y etiquetas sin ruido visual
plt.title('Proyección PCA 2D: Segmentación de Especies Iris', fontsize=14, fontweight='bold', pad=15)
plt.xlabel('Componente Principal 1 (PC1)', fontsize=12)
plt.ylabel('Componente Principal 2 (PC2)', fontsize=12)

# Ajuste de la leyenda fuera del gráfico
plt.legend(title='Especie', bbox_to_anchor=(1.05, 1), loc='upper left')
plt.tight_layout() # Previene que se corten los bordes al exportar la imagen

# Mostrar gráfico
plt.show()

# --- VALIDACIÓN MATEMÁTICA (EXTRA PARA TU REPORTE) ---
varianza = pca.explained_variance_ratio_
print(f"Varianza explicada por PC1: {varianza[0]*100:.2f}%")
print(f"Varianza explicada por PC2: {varianza[1]*100:.2f}%")
print(f"Información total retenida en 2D: {sum(varianza)*100:.2f}%")
```

3. Resultados Matemáticos (Varianza Retenida)

La transformación fue un éxito rotundo en términos de compresión de información. Al pasar de 4 dimensiones a solo 2, los resultados arrojaron lo siguiente:

- **Componente Principal 1 (PC1):** Capturó el **72.77%** de la varianza total.
- **Componente Principal 2 (PC2):** Capturó el **23.03%** de la varianza total.
- **Información Total Retenida: 95.80%**. Logramos reducir el volumen de datos a la mitad perdiendo únicamente un 4.2% de la información original.

```
--- Vista previa del DataFrame ---
   Componente 1  Componente 2  Target
0     -2.264703      0.480027  Setosa
1     -2.080961     -0.674134  Setosa
2     -2.364229     -0.341908  Setosa
3     -2.299384     -0.597395  Setosa
4     -2.389842      0.646835  Setosa
```

4. Traducción a Negocio: Interpretación del Mapa de Segmentación

Al proyectar nuestros dos nuevos componentes en un gráfico de dispersión, el algoritmo logró agrupar las especies de forma natural. De este mapa extraemos dos grandes hallazgos estratégicos:

- **El Nicho Aislado (Iris-setosa):** En el extremo izquierdo del gráfico (valores negativos de PC1), esta especie se separa limpiamente del resto. *Insight:* Esto representa un segmento con características y comportamientos radicalmente únicos. No requiere modelos predictivos complejos para ser identificado o clasificado.
- **La Zona de Competencia (Iris-versicolor e Iris-virginica):** Ubicadas en el centro y a la derecha del gráfico. Aunque el modelo logra agruparlas por color, existe una "frontera difusa" donde algunos puntos se superponen. *Insight:* Estos dos segmentos tienen perfiles altamente similares (posible canibalización si fueran productos). Tomar decisiones estratégicas para diferenciarlos requeriría un análisis más profundo.

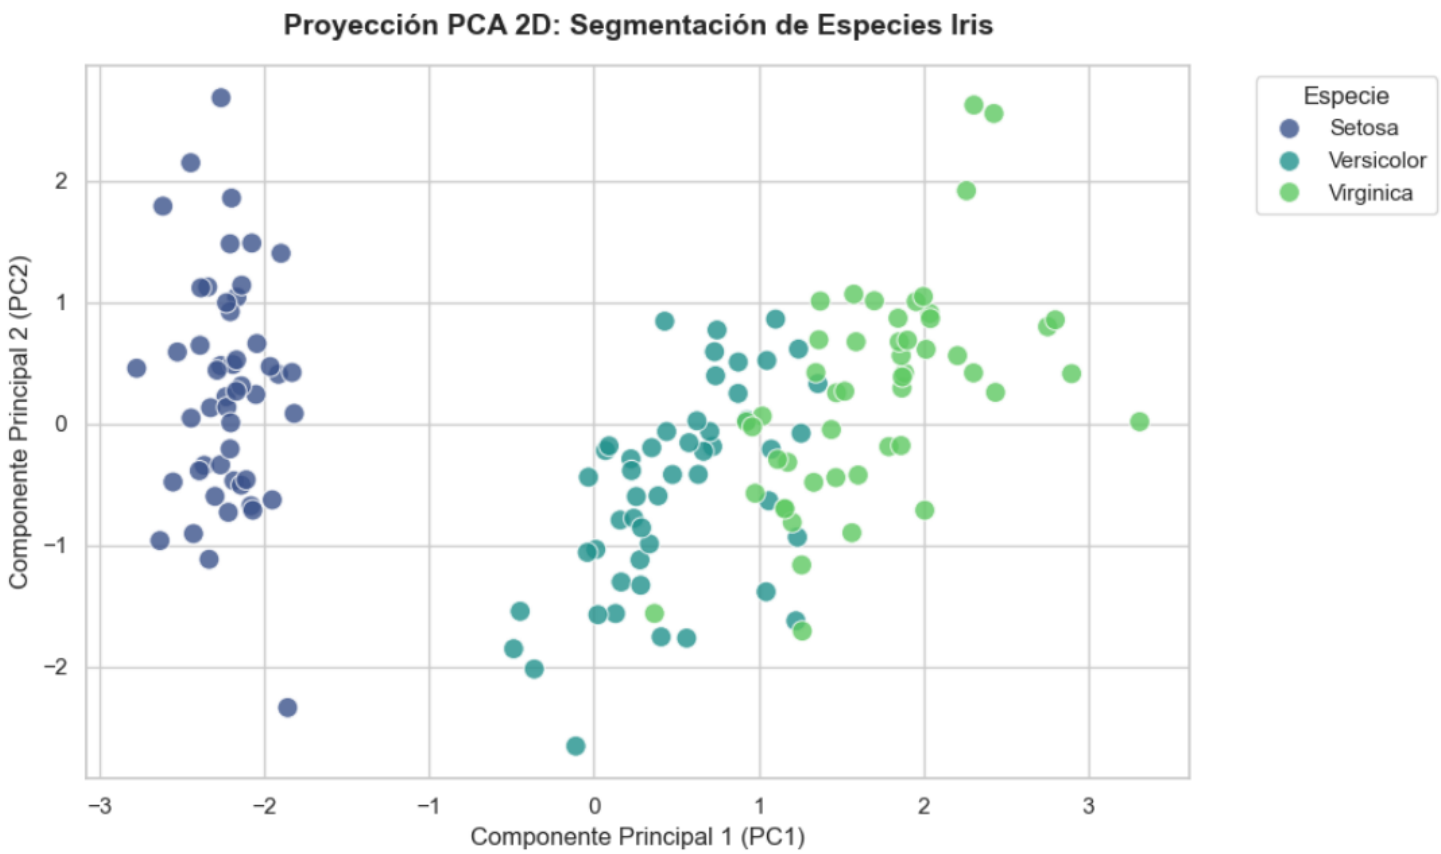


```
Varianza explicada por PC1: 72.96%
Varianza explicada por PC2: 22.85%
Información total retenida en 2D: 95.81%
```

5. Conclusión Estratégica

La aplicación de PCA demostró que podemos perfilar y segmentar eficientemente esta base de datos utilizando solo dos variables maestras. Esto se traduce en **modelos predictivos más rápidos, menor almacenamiento requerido y la capacidad de presentar visualizaciones ejecutivas claras** para la toma de decisiones.