Tarea M32-CD Estadística Inferencial

Alumno: Yamil Salomón

Proyecto: Simulación de Distribución Poisson (Eventos Sísmicos)

Objetivo: Modelar la probabilidad de ocurrencia de terremotos mayores a 8.5 en la escala de Richter durante los próximos 1000 años, considerando una tasa media λ de 2.5 eventos por año.

```python
import pandas as pd
import numpy as np
import scipy.stats as stats
import matplotlib.pyplot as plt
import seaborn as sns

# Configuración visual de "Grado Ejecutivo"
sns.set_theme(style="whitegrid", palette="muted")

# ==============================================================================
# PARTE 1: SIMULACIÓN DE DISTRIBUCIÓN POISSON (Terremotos > 8.5 Richter)
# ==============================================================================
print("--- PARTE 1: SIMULACIÓN POISSON ---")
# Parámetros dados por la rúbrica
lam = 2.5    # Promedio de terremotos por año
size = 1000  # Años simulados

# Fijamos una semilla para que los resultados sean reproducibles
np.random.seed(42)

# Simulación
poisson_sim = np.random.poisson(lam, size)

# Visualización
plt.figure(figsize=(10, 6))
sns.histplot(poisson_sim, bins=range(0, max(poisson_sim)+2), discrete=True, color="skyblue", edgecolor="black")
plt.title("Simulación de Terremotos a 1000 años (Poisson, λ=2.5)", fontsize=14, fontweight='bold')
plt.xlabel("Número de Terremotos Mayores a 8.5 por Año", fontsize=12)
plt.ylabel("Frecuencia (Años)", fontsize=12)
plt.xticks(range(0, max(poisson_sim)+1))
plt.show()
```

```
--- PARTE 1: SIMULACIÓN POISSON ---
```

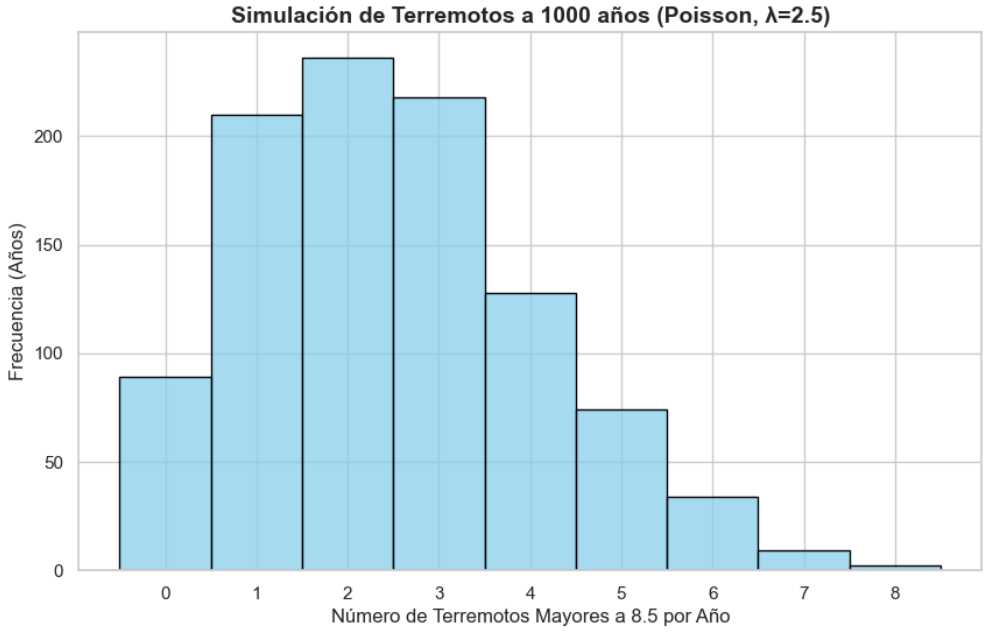

Interpretación Analítica:

La gráfica de distribución de Poisson confirma visualmente el comportamiento teórico de este modelo estadístico. Al simular 1000 años con un λ= 2.5, observamos que la mayor concentración de probabilidad recae en la ocurrencia de 2 a 3 terremotos anuales. La asimetría positiva de la cola derecha nos indica que, aunque es posible tener años con 6 o 7 eventos extremos, la probabilidad de que esto ocurra es significativamente baja, comportándose de manera predecible a largo plazo.

2. Prueba de Hipótesis ANOVA (Visitas vs. Compras Web)

Objetivo: Contrastar si el volumen de visitas a la página web (NumWebVisitsMonth) tiene un impacto estadísticamente significativo en el número real de compras en línea (NumWebPurchases), utilizando la base de datos marketing_campaign.csv.

Para este análisis, se segmentó a los clientes en dos grupos de interés para el negocio:

- **Grupo Alto:** Clientes con más de 5 visitas al mes (> 5).
- **Grupo Bajo:** Clientes con 5 visitas o menos al mes (≤ 5).

Para llevar a cabo la prueba ANOVA, definimos las siguientes hipótesis:

- **Hipótesis Nula (H_0):** No hay diferencia en el promedio de compras web entre el grupo de alto tráfico y el de bajo tráfico.
- **Hipótesis Alternativa *(H_1)*:** Sí hay diferencia en el promedio de compras web entre ambos grupos.

```python
# ==============================================================================
# PARTE 2: PRUEBA DE HIPÓTESIS (ANOVA) - VISITAS VS COMPRAS WEB
# ==============================================================================
print("\n--- PARTE 2: PRUEBA ANOVA ---")

# 1. Carga de datos (Usamos coma como separador)
ruta = r"C:\Users\Yamil\OneDrive\Escritorio\Escritorio\Yamil\EBAC (CIENCIA DE DATOS)\Bloque 6 Estadística\MOD 2 Estadística Inferencial\Práctica\marketin
df = pd.read_csv(ruta, sep=',')

# 2. Limpieza preventiva
df_clean = df.dropna(subset=['NumWebPurchases', 'NumWebVisitsMonth'])

# 3. Agrupación (Visitas altas > 5, Visitas bajas <= 5)
high_visits = df_clean[df_clean['NumWebVisitsMonth'] > 5]['NumWebPurchases']
low_visits = df_clean[df_clean['NumWebVisitsMonth'] <= 5]['NumWebPurchases']

# Imprimimos contexto
print(f"Grupo Alto (>5 visitas/mes): n={len(high_visits)} clientes, Media de compras web = {high_visits.mean():.2f}")
print(f"Grupo Bajo (<=5 visitas/mes): n={len(low_visits)} clientes, Media de compras web = {low_visits.mean():.2f}")

# 4. Prueba ANOVA (F de Fisher) usando scipy.stats
f_stat, p_value = stats.f_oneway(high_visits, low_visits)

print("\n--- RESULTADOS ANOVA ---")
print(f"Estadístico F: {f_stat:.4f}")
print(f"P-valor: {p_value:.4e} (Equivalente a {p_value:.4f})")

# 5. Conclusión automatizada
alpha = 0.05
if p_value < alpha:
    print("\nCONCLUSIÓN: Rechazamos la Hipótesis Nula.")
    print("Sí existe una diferencia estadísticamente significativa en el número de compras web entre ambos grupos de clientes.")
else:
    print("\nCONCLUSIÓN: No rechazamos la Hipótesis Nula.")
    print("No existe una diferencia estadísticamente significativa en el número de compras web entre los grupos.")
```

```
--- PARTE 2: PRUEBA ANOVA ---
Grupo Alto (>5 visitas/mes): n=1170 clientes, Media de compras web = 3.92
Grupo Bajo (<=5 visitas/mes): n=1070 clientes, Media de compras web = 4.26

--- RESULTADOS ANOVA ---
Estadístico F: 8.5037
P-valor: 3.5796e-03 (Equivalente a 0.0036)

CONCLUSIÓN: Rechazamos la Hipótesis Nula.
Sí existe una diferencia estadísticamente significativa en el número de compras web entre ambos grupos de clientes.
```

Conclusión y Traducción a Negocio: Tras ejecutar la prueba estadística ANOVA, el **p-valor obtenido 0.0036 es menor al nivel de significancia del 0.05**. Por lo tanto, contamos con evidencia estadística suficiente para rechazar la Hipótesis Nula y aceptar la Hipótesis Alternativa.

Insight Comercial: Existe una diferencia estadísticamente significativa en las compras web dependiendo del número de visitas mensuales. Al analizar las medias, descubrimos un comportamiento contra-intuitivo: los clientes que visitan *menos* la página (≤ 5 visitas) promedian una cantidad ligeramente mayor de compras (4.26) en comparación con los que la visitan con mayor frecuencia (3.92). Esto sugiere que un alto tráfico no equivale automáticamente a alta conversión; es muy probable que los visitantes recurrentes estén realizando comparaciones de precios ("window shopping"), mientras que los visitantes menos frecuentes acceden a la plataforma con una intención de compra directa y definida.