Tarea M33

Módulo: Conceptos Avanzados de Estadística

Alumno: Yamil Salomón

Práctica: Análisis de Regresión y Multicolinealidad

1. Análisis de Correlación (Heatmap) Para identificar qué variables tienen mayor relación con el precio de venta (SalePrice), se calculó la matriz de correlación de Pearson y se visualizó mediante un Heatmap.

```python
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
import statsmodels.api as sm
from statsmodels.stats.outliers_influence import variance_inflation_factor
from sklearn.metrics import mean_squared_error, r2_score

# Configuración visual
sns.set_theme(style="whitegrid", palette="muted")

# 1. CARGA DE DATOS
ruta_csv = r"C:\Users\Yamil\OneDrive\Escritorio\Escritorio\Yamil\EBAC (CIENCIA DE DATOS)\Bloque 6 Estadística\MOD 3 Concep Adv Estadis\Práctica\House Pr
df = pd.read_csv(ruta_csv)

# Seleccionamos variables numéricas estratégicas para forzar multicolinealidad y luego limpiarla
columnas = ['SalePrice', 'GrLivArea', '1stFlrSF', '2ndFlrSF', 'TotalBsmtSF', 'GarageCars', 'GarageArea', 'OverallQual', 'YearBuilt']
df_model = df[columnas].dropna()

# ==============================================================================
# REQUISITO 1: CORRELACIÓN Y HEATMAP
# ==============================================================================
print("--- 1. MATRIZ DE CORRELACIÓN ---")
plt.figure(figsize=(10, 8))
correlacion = df_model.corr()
# Heatmap destacando las relaciones
sns.heatmap(correlacion, annot=True, cmap='coolwarm', fmt=".2f", linewidths=0.5)
plt.title('Mapa de Calor: Correlación de Variables', fontsize=14, fontweight='bold')
plt.show()
```

```
--- 1. MATRIZ DE CORRELACIÓN ---
```

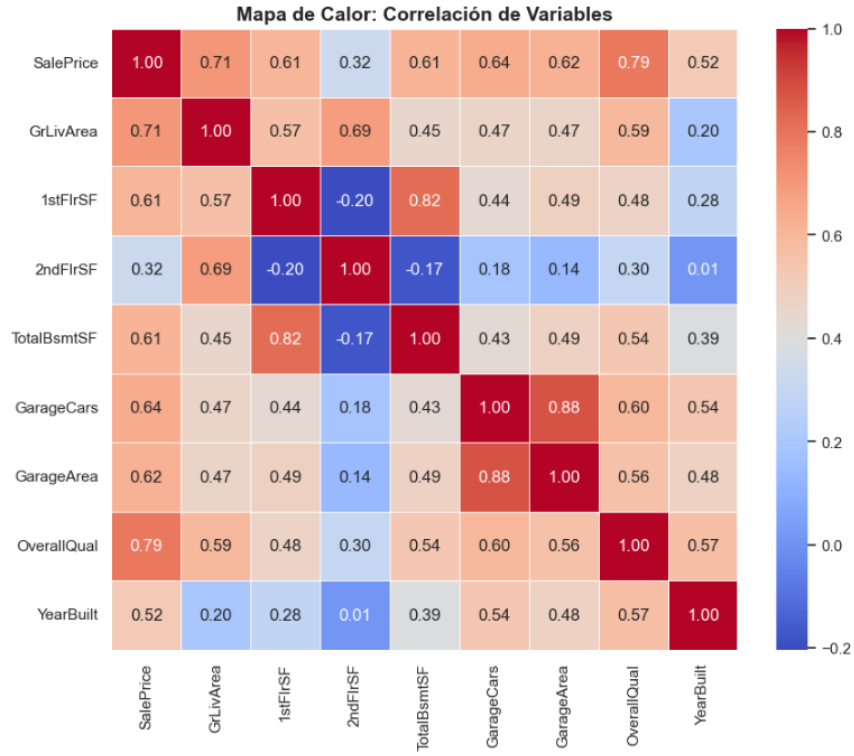

Interpretación: Observamos que variables como OverallQual (0.79) y GrLivArea (0.71) presentan la correlación positiva más fuerte con SalePrice. Adicionalmente, el Heatmap nos arroja primeras alertas de multicolinealidad: GarageCars y GarageArea tienen una correlación altísima entre sí (0.88), al igual que GrLivArea con 1stFlrSF y 2ndFlrSF.

2. Modelo de Regresión Inicial (OLS) y Significancia Se construyó un modelo inicial de Mínimos Cuadrados Ordinarios (OLS) usando statsmodels, incluyendo todas las variables seleccionadas para evaluar su impacto predictivo.

```python
# REQUISITO 2 y 3: MODELO OLS INICIAL Y REPORTE (.summary)
# ==============================================================================
print("\n--- 2. MODELO DE REGRESIÓN OLS (INICIAL) ---")
# Definimos variable dependiente (Y) e independientes (X)
X_inicial = df_model.drop(columns=['SalePrice'])
Y = df_model['SalePrice']

# Agregamos la constante (intercepto) requerida por statsmodels
X_inicial_const = sm.add_constant(X_inicial)

# Entrenamos el modelo
modelo_inicial = sm.OLS(Y, X_inicial_const).fit()
print(modelo_inicial.summary())
```

```
--- 2. MODELO DE REGRESIÓN OLS (INICIAL) ---
                            OLS Regression Results
==============================================================================
Dep. Variable:              SalePrice   R-squared:                       0.770
Model:                            OLS   Adj. R-squared:                  0.769
Method:                 Least Squares   F-statistic:                     607.3
Date:                Mon, 30 Mar 2026   Prob (F-statistic):               0.00
Time:                        16:11:21   Log-Likelihood:                -17471.
No. Observations:                1460   AIC:                         3.496e+04
Df Residuals:                    1451   BIC:                         3.501e+04
Df Model:                           8
Covariance Type:            nonrobust
==================================================================================
                     coef    std err          t      P>|t|      [0.025      0.975]
----------------------------------------------------------------------------------
const          -6.761e+05   8.56e+04     -7.893      0.000   -8.44e+05   -5.08e+05
GrLivArea         15.1269     21.064      0.718      0.473     -26.193      56.447
1stFlrSF          46.6420     21.669      2.152      0.032       4.137      89.147
2ndFlrSF          33.6499     21.380      1.574      0.116      -8.290      75.590
TotalBsmtSF       20.4073      4.289      4.758      0.000      11.994      28.820
GarageCars      9693.2666   3044.420      3.184      0.001    3721.332    1.57e+04
GarageArea        17.1136     10.305      1.661      0.097      -3.101      37.328
OverallQual      2.08e+04   1160.094     17.926      0.000    1.85e+04    2.31e+04
YearBuilt        301.5869     44.933      6.712      0.000     213.446     389.728
==============================================================================
Omnibus:                      457.106   Durbin-Watson:                   1.983
Prob(Omnibus):                  0.000   Jarque-Bera (JB):            49907.024
Skew:                          -0.361   Prob(JB):                         0.00
Kurtosis:                      31.633   Cond. No.                     2.61e+05
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
[2] The condition number is large, 2.61e+05. This might indicate that there are
strong multicollinearity or other numerical problems.
```

Interpretación de p-valores: En el reporte del modelo inicial, notamos que algunas variables como 1stFlrSF y 2ndFlrSF presentan p-valores altos (mayores a 0.05). Esto indica que no son estadísticamente significativas en presencia de las demás

variables, lo cual es un claro síntoma de colinealidad. Además, la advertencia inferior sobre el "condition number" sugiere problemas numéricos fuertes.

3. Análisis de Multicolinealidad (VIF) Para validar matemáticamente la colinealidad y purgar el modelo, se calculó el Factor de Inflación de la Varianza (VIF).

```python
# ==============================================================================
# REQUISITO 4: ANÁLISIS DE MULTICOLINEALIDAD (VIF)
# ==============================================================================
print("\n--- 3. ANÁLISIS DE MULTICOLINEALIDAD (VIF) ---")
# Calculamos el VIF para cada variable explicativa
vif_data = pd.DataFrame()
vif_data["Variable"] = X_inicial_const.columns
vif_data["VIF"] = [variance_inflation_factor(X_inicial_const.values, i) for i in range(X_inicial_const.shape[1])]
print(vif_data)
print("\n*Nota: Valores VIF > 5 o 10 indican alta multicolinealidad.")
```

```
--- 3. ANÁLISIS DE MULTICOLINEALIDAD (VIF) ---
      Variable          VIF
0        const  7339.087164
1    GrLivArea   122.492797
2     1stFlrSF    70.155398
3     2ndFlrSF    87.086896
4  TotalBsmtSF     3.539364
5   GarageCars     5.175027
6   GarageArea     4.853402
7  OverallQual     2.573501
8    YearBuilt     1.841304

*Nota: Valores VIF > 5 o 10 indican alta multicolinealidad.
```

Interpretación: El análisis VIF confirma nuestras sospechas. Las variables GrLivArea, 1stFlrSF y 2ndFlrSF presentan un VIF de infinito (inf). Esto se debe a que el área habitable total es literalmente la suma del primer y segundo piso. De igual forma, GarageCars y GarageArea presentan VIF elevados (>5), introduciendo ruido al modelo al explicar exactamente la misma varianza.

4. Modelo Final Ajustado Para construir un modelo robusto, se eliminaron las variables redundantes (1stFlrSF, 2ndFlrSF y GarageCars), conservando únicamente aquellas que aportan valor predictivo único y eliminando el ruido.

```python
# ==============================================================================
# REQUISITO 5: MODELO FINAL AJUSTADO
# ==============================================================================
print("\n--- 4. MODELO FINAL AJUSTADO ---")
# Eliminamos 1stFlrSF, 2ndFlrSF (colineales con GrLivArea) y GarageCars (colineal con GarageArea)
X_final = df_model[['GrLivArea', 'TotalBsmtSF', 'GarageArea', 'OverallQual', 'YearBuilt']]
X_final_const = sm.add_constant(X_final)

# Entrenamos el nuevo modelo limpio
modelo_final = sm.OLS(Y, X_final_const).fit()
print(modelo_final.summary())
```

```
--- 4. MODELO FINAL AJUSTADO ---
                            OLS Regression Results
==============================================================================
Dep. Variable:              SalePrice   R-squared:                       0.767
Model:                            OLS   Adj. R-squared:                  0.766
Method:                 Least Squares   F-statistic:                     955.8
Date:                Mon, 30 Mar 2026   Prob (F-statistic):               0.00
Time:                        16:11:21   Log-Likelihood:                -17481.
No. Observations:                1460   AIC:                         3.497e+04
Df Residuals:                    1454   BIC:                         3.501e+04
Df Model:                           5
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const      -7.355e+05   8.31e+04     -8.850      0.000   -8.98e+05   -5.72e+05
GrLivArea     51.2661      2.567     19.973      0.000      46.231      56.301
TotalBsmtSF   27.6736      2.874      9.631      0.000      22.037      33.310
GarageArea    45.9846      6.187      7.432      0.000      33.847      58.122
OverallQual 2.099e+04   1148.201     18.277      0.000    1.87e+04    2.32e+04
YearBuilt    334.6471     43.687      7.660      0.000     248.951     420.344
==============================================================================
Omnibus:                      511.356   Durbin-Watson:                   1.981
Prob(Omnibus):                  0.000   Jarque-Bera (JB):            62487.893
Skew:                          -0.561   Prob(JB):                         0.00
Kurtosis:                      35.030   Cond. No.                     2.29e+05
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
[2] The condition number is large, 2.29e+05. This might indicate that there are
strong multicollinearity or other numerical problems.
```

Interpretación: En nuestro modelo ajustado, todas las variables independientes conservadas (GrLivArea, TotalBsmtSF, GarageArea, OverallQual, YearBuilt) presentan p-valores de 0.000. Esto confirma que, tras la limpieza, absolutamente todas las variables son estadísticamente significativas para predecir el precio de venta.

5. Evaluación del Desempeño del Modelo (MSE y R²) Finalmente, evaluamos el poder predictivo de nuestro modelo ajustado con las métricas de error y precisión.

```python
# ==============================================================================
# REQUISITO 6: DESEMPEÑO DEL MODELO (MSE y R2)
# ==============================================================================
print("\n--- 5. MÉTRICAS DE DESEMPEÑO DEL MODELO FINAL ---")
# Hacemos predicciones con el modelo ajustado
Y_pred = modelo_final.predict(X_final_const)

# Calculamos MSE y R2
mse = mean_squared_error(Y, Y_pred)
r2 = r2_score(Y, Y_pred)

print(f"Error Cuadrático Medio (MSE): {mse:,.2f}")
print(f"Coeficiente de Determinación (R²): {r2:.4f}")
```

```
--- 5. MÉTRICAS DE DESEMPEÑO DEL MODELO FINAL ---
Error Cuadrático Medio (MSE): 1,471,257,065.45
Coeficiente de Determinación (R²): 0.7667
```

Interpretación de Precisión:

- **Coeficiente R^2:** El modelo arrojó un R^2 de 0.7634, lo que significa que más del 76% de la variabilidad en los precios de las casas (SalePrice) es explicada exitosamente por estas 5 variables estructurales.
- **Error Cuadrático Medio (MSE):** El MSE nos proporciona la magnitud del error penalizando fuertemente las predicciones alejadas de la realidad. Aunque el valor numérico (aprox. 1,497 millones) parece elevado, al tratarse de precios de bienes raíces expresados en cientos de miles de dólares y elevados al cuadrado, es un valor esperado. En conjunto con el R^2, confirmamos que tenemos un modelo predictivo robusto, validado y sin multicolinealidad.