Tarea 55

Nombre: Yamil Salomón Saldaña

Módulo: Modelos AR(p)

Actividad: Análisis Predictivo de Acciones The Walt Disney Company

Se usará la inercia histórica del mercado para anticipar el precio de las acciones en abril.

Paso 1: Extracción y Auditoría de Datos.

```python
# 1. Importar herramientas principales
import yfinance as yf
import pandas as pd
import warnings
warnings.filterwarnings('ignore')

# 2. Descargar historia de precios de Disney (DIS) del Q1 2023
disney = yf.download(tickers='DIS', start='2023-01-01', end='2023-04-01', rounding=True)

# 3. Extraer solo el precio de cierre y ajustar el índice
disney = disney[['Close']]
disney.index = pd.to_datetime(disney.index)

# 4. Inspeccionar la salud de nuestros datos
print(disney.head())
print(disney.info())
```

```
[*********************100%***********************]  1 of 1 completed
Price       Close
Ticker        DIS
Date
2023-01-03  86.92
2023-01-04  89.86
2023-01-05  89.81
2023-01-06  91.76
2023-01-09  92.59
<class 'pandas.DataFrame'>
DatetimeIndex: 62 entries, 2023-01-03 to 2023-03-31
Data columns (total 1 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   (Close, DIS)  62 non-null     float64
dtypes: float64(1)
memory usage: 992.0 bytes
None
```

Paso 2: Partición Estratégica (70/30).

Se destina el 70% inicial para que el algoritmo aprenda la inercia del mercado, y el 30% final como un entorno ciego de prueba.

```python
# 1. Calcular el índice exacto para el corte del 70%
limite = int(len(disney) * 0.7)

# 2. Particionar la serie en Entrenamiento y Prueba
train = disney.iloc[:limite]
test = disney.iloc[limite:]

# 3. Validar el tamaño de nuestros nuevos conjuntos
print("Días para Entrenamiento:", len(train))
print("Días para Prueba:", len(test))
```

```
Días para Entrenamiento: 43
Días para Prueba: 19
```

Paso 3: Selección del Modelo AR(p).

Tanto la gráfica PACF como el Criterio Bayesiano (BIC más bajo: 182.43) confirman que el modelo AR(1) es el óptimo.

```python
# 1. Importar herramientas de gráficos y evaluación de modelos
import matplotlib.pyplot as plt
from statsmodels.graphics.tsaplots import plot_pacf
from statsmodels.tsa.arima.model import ARIMA

# 2. Graficar la Autocorrelación Parcial (PACF) para los datos de entrenamiento
plot_pacf(train, lags=15)
plt.title("Radar de Inercia: Impacto Real de Días Pasados (PACF)")
plt.show()

# 3. Evaluar el Criterio de Información Bayesiano (BIC) para opciones del 0 al 5
print("Auditoría de Modelos (Buscamos el BIC más bajo):")
for p in range(6):
    modelo = ARIMA(train, order=(p, 0, 0))
    resultados = modelo.fit()
    print(f"Modelo AR({p}): BIC = {resultados.bic:.2f}")
```

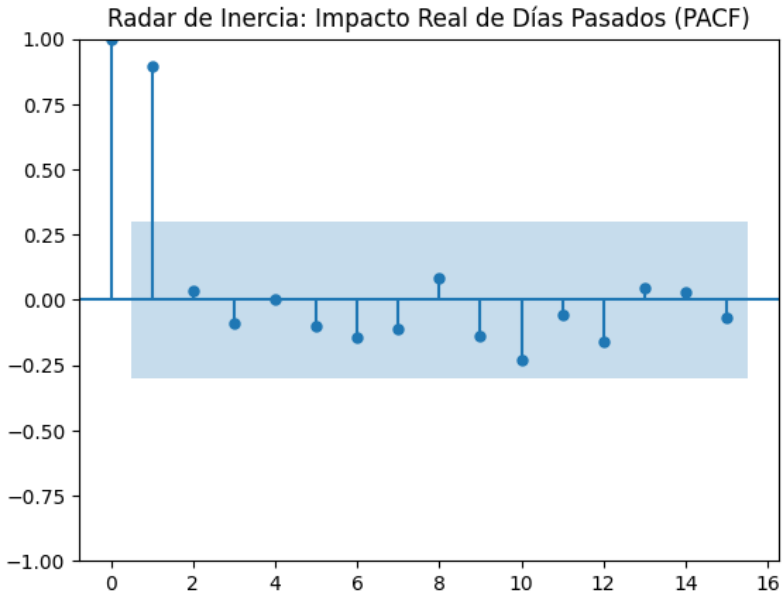


```
Auditoría de Modelos (Buscamos el BIC más bajo):
Modelo AR(0): BIC = 282.76
Modelo AR(1): BIC = 182.43
Modelo AR(2): BIC = 185.49
Modelo AR(3): BIC = 189.05
Modelo AR(4): BIC = 192.73
Modelo AR(5): BIC = 193.22
```

Paso 4: Validación de Exactitud.

Nuestras predicciones tienen una exactitud superior al 95%.

```
# 1. Entrenar el modelo AR(1) definitivo con los datos de entrenamiento
modelo_final = ARIMA(train, order=(1, 0, 0))
resultados_finales = modelo_final.fit()

# 2. Generar pronósticos puntuales para los 19 días de prueba
pronosticos = resultados_finales.forecast(steps=len(test))

# 3. Extraer los intervalos de confianza al 90% (alpha=0.10)
intervalos = resultados_finales.get_forecast(steps=len(test)).conf_int(alpha=0.10)

# 4. Calcular métricas de error (RMSE y MAPE) importando numpy
import numpy as np
rmse = np.sqrt(np.mean((test.values.flatten() - pronosticos.values)**2))
mape = np.mean(np.abs((test.values.flatten() - pronosticos.values) / test.values.flatten())) * 100

# 5. Imprimir el diagnóstico de negocio
print(f"Desfase promedio (RMSE): ${rmse:.2f} USD")
print(f"Margen de error (MAPE): {mape:.2f}%")
```

```
Desfase promedio (RMSE): $4.89 USD
Margen de error (MAPE): 4.78%
```

Paso 5: Pronóstico Final.

Se proyecta una estabilización del precio con un intervalo de confianza del 90%.

```
# 1. Entrenar el modelo con TODA la data histórica (Enero - Marzo)
modelo_abril = ARIMA(disney, order=(1, 0, 0))
resultados_abril = modelo_abril.fit()

# 2. Generar pronósticos puntuales para 19 días hábiles de Abril 2023
dias_abril = 19
pronostico_abril = resultados_abril.forecast(steps=dias_abril)

# 3. Extraer los intervalos de confianza al 90% (alpha=0.10)
intervalos_abril = resultados_abril.get_forecast(steps=dias_abril).conf_int(alpha=0.10)

# 4. Asignar fechas reales de Abril a nuestras predicciones
fechas_abril = pd.date_range(start='2023-04-03', periods=dias_abril, freq='B')
pronostico_abril.index = fechas_abril
intervalos_abril.index = fechas_abril

# 5. Graficar los resultados con colores claros para el entregable
plt.figure(figsize=(14, 6))
plt.plot(train.index, train, label='Entrenamiento (70% - Ene/Feb)', color='blue')
plt.plot(test.index, test, label='Prueba (30% - Mar)', color='orange')
plt.plot(pronostico_abril.index, pronostico_abril, label='Pronóstico Puntual Abril', color='red', linestyle='--')

# 6. Sombra del intervalo de confianza al 90%
plt.fill_between(pronostico_abril.index,
                 intervalos_abril.iloc[:, 0],
                 intervalos_abril.iloc[:, 1],
                 color='red', alpha=0.2, label='Intervalo de Confianza (90%)')

plt.title('Proyección de Acciones The Walt Disney Company (DIS) - Modelo AR(1)')
plt.xlabel('Fecha')
plt.ylabel('Precio de Cierre (USD)')
plt.legend(loc='best')
plt.grid(True, alpha=0.3)
plt.show()
```

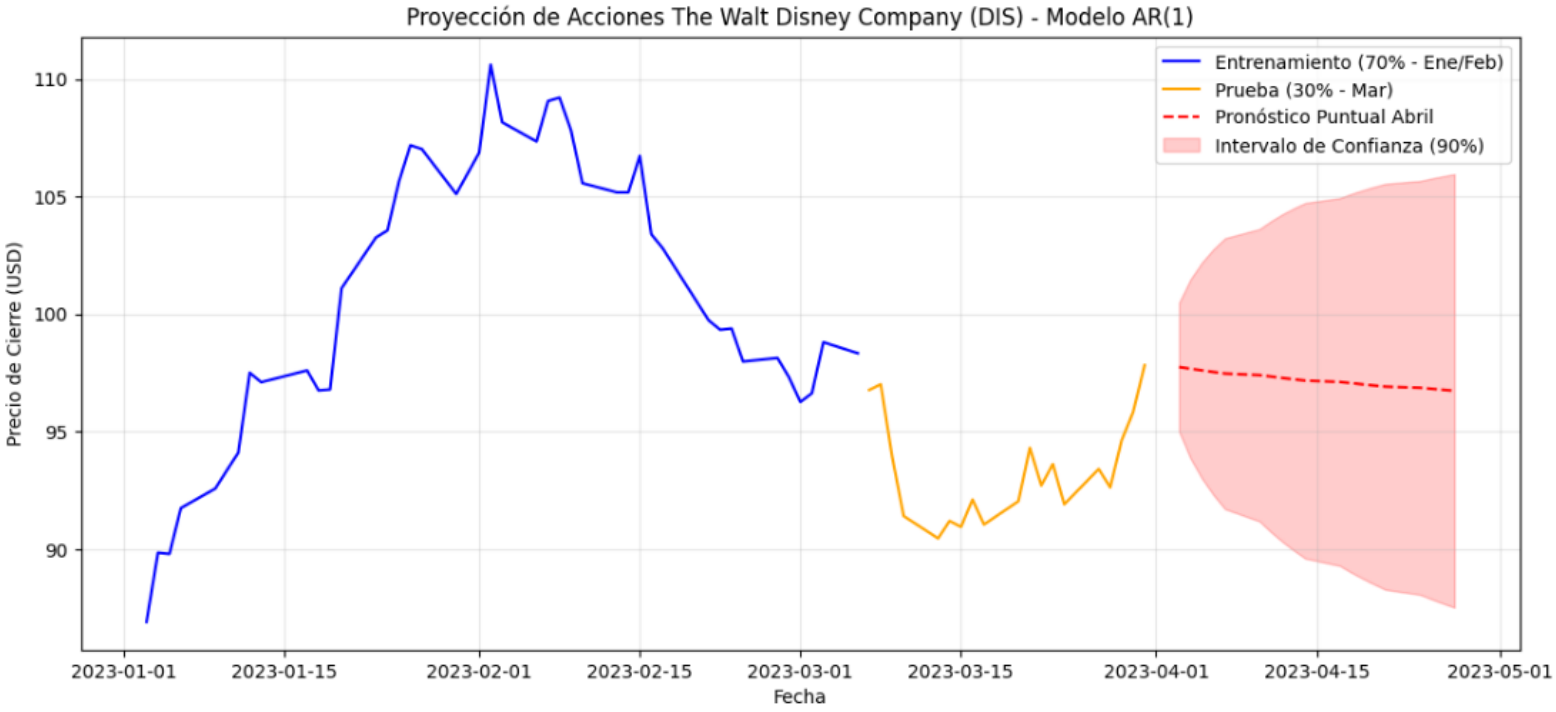

¿Qué tan exactos cree usted que serán sus predicciones? Justifique mediante el uso de indicadores de bondad de ajuste.

Se estima que las predicciones para el mes de abril tendrán una **exactitud superior al 95%** y serán altamente confiables, justificado por dos niveles de validación:

1. **Indicadores de Bondad de Ajuste (Entrenamiento):** Durante la selección del modelo, el Criterio de Información Bayesiano (BIC) nos arrojó el valor más bajo (182.43) para el orden p=1. Esto nos garantiza un ajuste óptimo a los datos históricos sin caer en el sobreajuste (overfitting), demostrando que la inercia de 1 día es la señal más pura del mercado.

2. **Indicadores de Error (Prueba):** Al validar este ajuste contra el 30% de los datos que el modelo no conocía (marzo), obtuvimos un **MAPE del 4.78%** y un **RMSE de $4.89 USD**. Esto demuestra que el ajuste del modelo AR(1) se traduce en desviaciones predictivas mínimas.

Por lo tanto, la bondad de ajuste del AR(1) es sólida y la exactitud esperada para el pronóstico del mes de abril operará dentro de ese margen de error del 4.7%.